

UNIVERSIDADE FEDERAL DO PAMPA

GABRIEL LOPES SILVA

**ANALISE DO COMPORTAMENTO DA
B3, EM DIFERENTES ESTADOS DO
MERCADO, ANTE TÉCNICAS REDES
NEURAIS ARTIFICIAIS**

**Bagé
2020**

GABRIEL LOPES SILVA

**ANALISE DO COMPORTAMENTO DA
B3, EM DIFERENTES ESTADOS DO
MERCADO, ANTE TÉCNICAS REDES
NEURAIS ARTIFICIAIS**

Trabalho de Conclusão de Curso apresentado ao curso de Bacharelado em Engenharia de Computação como requisito parcial para a obtenção do grau de Bacharel em Engenharia de Computação.

Orientador: Sandro da Silva Camargo

**Bagé
2020**

Ficha catalográfica elaborada automaticamente com os dados fornecidos pelo(a) autor(a) através do Módulo de Biblioteca do Sistema GURI (Gestão Unificada de Recursos Institucionais).

-- Silva, Gabriel Lopes

 Análise do comportamento da B3, em diferentes estados do mercado, ante técnicas redes neurais artificiais / Gabriel Lopes Silva.

 71 p.

 Trabalho de Conclusão de Curso (Graduação) – Universidade Federal do Pampa, ENGENHARIA DE COMPUTAÇÃO, 2020.

 "Orientação: Sandro da Silva Camargo".

 1. Bovespa. 2. B3. 3. Renda variável. 4. LSTM. 5. Mercado de ações. 6. RNA.

I. Título.

GABRIEL LOPES SILVA

**ANALISE DO COMPORTAMENTO DA
B3, EM DIFERENTES ESTADOS DO
MERCADO, ANTE TÉCNICAS REDES
NEURAIS ARTIFICIAIS**

Trabalho de Conclusão de Curso apresentado
ao curso de Bacharelado em Engenharia de
Computação como requisito parcial para a
obtenção do grau de Bacharel em Engenharia de
Computação.

Trabalho de Conclusão de Curso defendido e aprovado em: 29 de junho de
2019.

Banca examinadora:

Prof. Dr. Sandro da Silva Camargo
Orientador

Prof. Dr. Leonardo Bidese de Pinho
Universidade Federal do Pampa

Prof^a. Dr^a. Ana Paula Lüdtke Ferreira
Universidade Federal do Pampa

RESUMO

Este trabalho visa analisar a capacidade do método rede neural, do tipo LSTM (*Long short-term memory*), em prever as movimentações do mercado de ações da B3 no ano de 2019. A fim de representar o mercado da B3 (Brasil Bolsa Balcão) foram selecionadas 5 ações, que somadas representam mais de 45% do valor total do mercado da B3 no ano de 2019. Analisando os valores de volume e preços de abertura, máximos, mínimos e fechamento de cinco dias, as redes retornam os valores de preço de abertura e preço de fechamento do próximo dia. Foi abordado a seleção de *hyper* parâmetros e gerado modelos para predição das ações propostas, que atingiram coeficientes de determinação de até 0,99.

Palavras-chave: Bovespa. B3. Renda variável. LSTM. Mercado de ações. RNA.

ABSTRACT

Keywords: Bovespa. B3. variant profit. LSTM. Stock Market. ANN.

LISTA DE FIGURAS

Figura 1	Magazine Luiza	16
Figura 2	Padrões MAGLU3	17
Figura 3	Rede Neural Artificial.....	23
Figura 4	Neurônio artificial.....	23
Figura 5	Funções de ativação	24
Figura 6	Rede Neural Artificial de múltiplas camadas	25
Figura 7	Funcionamento do <i>Kernel</i>	26
Figura 8	Redes Neurais Recorrentes	28
Figura 9	LSTM.....	29
Figura 10	<i>Grid Search</i>	31
Figura 11	<i>Grid Search 2</i>	31
Figura 12	Abordagem 1	37
Figura 13	Abordagem 2	38
Figura 14	<i>Rede I</i>	41
Figura 15	<i>Rede II</i>	41
Figura 16	<i>Predição AMBEV 2019</i>	42
Figura 17	<i>Predição BBDC 2019</i>	42
Figura 18	<i>Predição ITUB 2019</i>	43
Figura 19	<i>Predição PETR 2019</i>	43
Figura 20	<i>Predição VALE 2019</i>	44

LISTA DE TABELAS

Tabela 1	Interpretação de EMPA.....	32
Tabela 2	Trabalhos correlatos.....	33
Tabela 3	Características das amostras	36
Tabela 4	Variações.....	39
Tabela 5	Grid Search	40
Tabela 6	Avaliação das ações	46
Tabela 7	Predição de modelos em ações distintas (Abertura).....	47
Tabela 8	Predição de modelos em ações distintas (Fechamento)	48
Tabela 9	Modelos com melhores resultados que original (Abertura)	48
Tabela 10	Modelos com melhores resultados que original (Fechamento).....	48
Tabela 11	Comparação com trabalhos correlatos.....	49
Tabela 13	Avaliação das ações	63

LISTA DE ABREVIATURAS E SIGLAS

ARIMA	<i>Autoregressive integrated moving average</i>
B3	Brasil Bolsa Balcão
CD	Coeficiente de determinação
CNN	<i>Convolutional Neural Network</i>
CVM	Comissão de Valores Mobiliários
DPA	Desvio padrão amostral
EMPA	Erro médio percentual absoluto
EQM	Erro quadrático médio
HMM	<i>Hidden Markov Model</i>
IBOV	Índice Bovespa
LSTM	<i>Long Short-term Memory</i>
MLP	<i>Multilayer Perceptron</i>
NASDAQ	<i>National Association of Securities Dealers Automated Quotations</i>
NIFTY	<i>National Stock Exchange of India</i>
REQM	Raíz do erro quadrático médio
ReLU	<i>Rectified Linear Activation Unit</i>
RNA	<i>Rede Neural Artificial</i>
RNN	<i>Recurrent Neural Network</i>
RSI	<i>Relative Strength Index</i>
SMA	<i>Simple Moving Average</i>
TAM	Taxa de acerto média
TVE	Taxa de variação esperada
VM	Variação média

SUMÁRIO

1 INTRODUÇÃO	10
1.1 Justificativa	11
1.2 Problema	11
1.3 Objetivos	11
1.4 Organização deste trabalho	12
2 FUNDAMENTAÇÃO TEÓRICA	13
2.1 Mercado de ações	13
2.2 Métodos de previsão de retorno.....	14
2.3 Elementos da Análise Técnica.....	16
2.3.1 Indicadores	17
2.3.2 Teoria de Dow	18
2.4 Séries temporais	20
2.5 Aprendizado de Máquina	21
2.6 Redes Neurais Artificiais	22
2.6.1 Funções de ativação	22
2.7 Arquiteturas de redes neurais.....	24
2.7.1 <i>Feedforward</i>	25
2.7.2 Redes Neurais Recorrentes	27
2.7.3 Otimizando <i>Hyper</i> parâmetros	29
2.8 Formas de avaliar resultados	30
2.9 Trabalhos Correlatos	32
3 METODOLOGIA	35
3.1 Classificação desta pesquisa	35
3.2 Material e Métodos	35
3.3 Base de dados	36
3.4 Aprendizado de Máquina	37
4 ABORDAGEM PROPOSTA.....	39
4.1 Análise do conjunto de dados	39
4.2 Seleção de <i>Hyper</i> parâmetros	40
4.3 Resultados experimentais.....	41
4.4 Comparação com trabalhos correlatos	45
5 CONCLUSÕES	50
5.1 Dificuldades e limitações.....	50
5.2 Trabalhos futuros.....	52
REFERÊNCIAS	53
APÊNDICE A – GRID SEARCH.....	57
APÊNDICE A – TODAS AS AÇÕES	62
ANEXO A – COTAÇÕES HISTÓRICAS	64

1 INTRODUÇÃO

A Bolsa de Valores é uma instituição que intermedia venda e compra de bens, como produtos agrícolas, matérias-primas e valores mobiliários (GOMES, 1997). Uma de suas divisões, o mercado de capitais, é o responsável pela distribuição dos valores mobiliários, como ações, debêntures, promissórias de curto prazo, entre outros. Esse mercado tem como objetivo levantar capital para as empresas e proporcionar lucros para os investidores. O mercado de ações é um dos subconjuntos do mercado de captais, no qual a variação das ações e o compartilhamento dos lucros são o que motiva os investidores a atuar neste mercado.

Com o intuito de prever as ações do mercado financeiro, que podem ser analisadas como séries temporais, estudiosos vêm propondo diferentes métodos e técnicas. Contudo, as séries temporais do mercado financeiro, preços de cambio e indicadores são influenciados por múltiplos fatores, fazendo com que sua predição se torne complexa (FREDERIC, 2004). Edwards, Magee e Bassetti (2018) nos apresentam duas técnicas para tentar prever estas movimentações. A primeira delas é chamada análise técnica, que se baseia na observação de gráficos, de períodos passados, para tentar prever o comportamento futuro do mercado. A outra é a análise fundamentalista, que se baseia em fatores econômicos e observações das operações realizadas pela empresa, para tentar prever como o seu valor irá se alterar.

Como o processamento matemático, quando realizado por humanos, é limitado, são utilizados computadores para ampliar a capacidade de processamento excussão de técnicas de análise. Hsu et al. (2016) demonstram que técnicas de *machine learning* (aprendizado de máquina), são mais eficientes do que métodos puramente econômicos baseados em observações. Dentre as técnicas de *machine learning* a utilização de RNA (Redes Neurais Artificiais), vem sendo empregadas na tarefa de predizer o mercado de ações (ATSALAKIS; VALAVANIS, 2009). A eficiência desta técnica pode variar dependendo de alguns fatores: situação em que o mercado se encontra, em ascendência, descendência ou estagnado; perfil socioeconômica do país, ou região, ao qual o mercado está situado, capitalista, socialista, comunista dentre outros; assim como crises econômicas, movimentos separatistas e doenças são alguns dos fatores que podem influenciar o desempenho da técnica de RNA (DASE; PAWAR, 2010; BAK; PACZUSKI; SHUBIK, 1996; GRIMA; CARUANA, 2017).

1.1 Justificativa

Na literatura são encontrados diversos trabalhos com o objetivo de mesurar o desempenho de RNA sob algum mercado de ações (ROONDIWALA; PATEL; VARMA, 2017; SELVIN et al., 2017; MOGHADDAM; MOGHADDAM; ESFANDYARI, 2016; HASSAN; NATH; KIRLEY, 2007). Contudo, como explicado por Vui et al. (2013), o desempenho de redes neurais artificiais na predição de um conjunto de ações é afetado por alguns fatores, dentre eles a região do mercado, situação do mercado, período analisado entre outros.

1.2 Problema

Treinar uma RNA, com os dados relativos aos anos de 2015 a 2018 para que, quando analisar um conjunto de cinco dias do ano de 2019, consiga prever o preço de abertura e fechamento do próximo dia.

1.3 Objetivos

Este trabalho possui como objetivo realizar uma análise de desempenho de duas abordagens de RNA, do tipo RNR (Redes Neurais Recorrentes), na previsão do comportamento de ações no mercado de renda variável, delimitando como estudo de caso um conjunto de ações negociadas na B3 (Brasil Bolsa Balcão) no período de 2019. A primeira abordagem tentará prever o preço de abertura da ação analisando os cinco dias prévios, e a segunda o preço de fechamento.

Dentre seus objetivos específicos estão:

- Identificar abordagens para avaliar os níveis de volatilidade das ações.
- Identificar técnicas de otimização que complementam as RNR.
- Projetar, treinar e testar a abordagem proposta.

1.4 Organização deste trabalho

O restante deste trabalho está organizado da seguinte forma: O Capítulo 2 aborda conceitos básicos, cruciais para elaboração e compreensão do trabalho. O Capítulo 3 discute quais foram as metodologias utilizadas para a construção do trabalho, assim como os materiais e as decisões tomadas. O Capítulo 4 apresenta a implementação do método proposto e seus resultados. O Capítulo 5 resume o que foi feito e possíveis alternativas para a continuidade deste trabalho.

2 FUNDAMENTAÇÃO TEÓRICA

Neste capítulo são apresentados os conceitos fundamentais para compreensão deste trabalho, discutindo o mercado de ações (seção 2.1), assim como métodos utilizados para modelar este problema (seções 2.2, 2.3, 2.5, 2.4, 2.6, 2.7). Também são abordadas formas de metrificar os resultados obtidos (seção 2.8), por fim são apresentados trabalhos correlatos (seção 2.9).

2.1 Mercado de ações

Conforme Mishkin (2007), mercado de ações é um subconjunto do mercado financeiro, que é composto pelos seguintes mercados: mercado monetário, mercado de renda fixa, mercado de divisas, mercado de derivados e mercado de renda variável, mais conhecido como mercado de ações. No mercado de ações empresas vendem pequenas frações do seu capital social, e investidores as compram visando o lucro, que pode ser obtido de duas formas: pelo ganho de capitais ou por dividendo.

- **Lucro pelo ganho de capital** - O preço das ações variam, por causas diversas, assim como explicado por Edwards, Magee e Bassetti (2018), tais como as expectativas geradas por investidores, tendências de mercado, a oferta e demanda por ações, entre outras. Investidores podem assim lucrar em decorrência destas variações. Caso o investidor queira lucrar a partir de variações acidentais de determinada ação, ele deve comprar esta ação e, estando em sua posse, pode vendê-la assim que julgar necessário, isto é denominado venda coberta. Caso o investidor queira lucrar com a depreciação de determinada ação, ele pode alugá-la e, caso a ação venha a cair, lucrar com o evento, contudo, o mesmo terá prejuízo caso a ação ganhe valor, esta prática é chamada de venda descoberta (SAFFI; SIGURDSSON, 2011).
- **Lucro por dividendo** - Parte dos lucros das empresas são divididos entre os seus acionistas, logo se pode lucrar adquirindo ações de empresas e esperar pelos seus respectivos lucros.

As ações também são agrupadas em diferentes categorias destacando-se as ordinárias e as preferenciais.

- **Ações ordinárias** - São aquelas que dão ao acionista o direito de influenciar ou até mesmo ditar a direção que a empresa vai seguir. Caso na empresa haja um acionista

majoritário, aquele que possua mais de 50% das ações ordinárias da empresa, ditará os rumos que a empresa vai tomar. Se não houver um acionista majoritário, será formada uma assembleia com os acionistas ordinários da empresa para tomar as decisões.

- **Ações preferenciais** - Esta ação não concede direito a voto, contudo ela terá preferências no recebimento dos dividendos, possuindo também maior liquidez do que a ação ordinária. Este modelo de ação é exclusivo do mercado brasileiro.

Há também dois tipos de mercado nos quais se pode adquirir ações.

- **Mercado primário** - Quando uma empresa decide abrir seu capital e disponibilizar suas ações para venda, ela deve registrar suas ações no mercado primário. Estes mercados vão conter uma lista com todas as ações da empresa e seus preços. Assim investidores podem procurar o mercado primário para a compra destas ações.
- **Mercado secundário** - Caso investidores decidam vender suas ações, é no mercado secundário que eles devem negociá-las. Neste mercado é possível a compra e venda de ações que já não estão mais no mercado primário.

Atualmente no Brasil, o B3 é a único mercado de ações e a instituição que organiza, registra e fiscaliza o ele, é a CVM (Comissão de Valores Mobiliários).

2.2 Métodos de previsão de retorno

Devido às flutuações do mercado de ações, foram desenvolvidos métodos para tentar prever padrões e possivelmente o comportamento do mercado. Raschke e Connors (1996) dizem que o sucesso de um método depende de três parâmetros:

- **Deve ser conceitualmente correto** - Ele deve ser baseado em conhecimento já adquirido e comprovado no mercado, de modo a não afrontar outros conhecimentos já comprovados sobre o mercado.
- **Deve fornecer uma cauda curta** - Ele tem que considerar a probabilidade de tomar uma decisão incorreta, que leve a perdas, e esta probabilidade deve ser menor que de lucro. Em um período longo, os lucros devem ser sempre maiores que as perdas.
- **Deve ser capaz de tratar uma situação desfavorável** - Circunstâncias desfavoráveis e pouco previsíveis tendem a ocorrer e, para que um método seja eficiente, ele deve ser capaz de contabilizar que tais situações irão acontecer e se ajustar a elas.

Para Edwards, Magee e Bassetti (2018), é possível classificar os métodos de previsão de retorno em dois grupos, análise fundamentalista e análise técnica .

Análise Fundamentalista

De acordo com Connors e Connors (1998), a técnica de análise fundamentalista consiste em obter a maior quantidade possível de informações sobre a empresa e sobre os fatores que a influenciam e ,então, tentar prever como o seu valor de mercado irá se comportar com base nestas informações.

Alguns exemplos de dados a serem analisados neste contexto são:

- **Balancos patrimoniais** - Relatório contábil com a síntese de todas as movimentações financeiras da empresa.
- **Relatório de Dividendos** - Qual é o dividendo gerado pela empresa.
- **Cenário político** - O que vai acontecer com uma empresa caso políticos com certos ideais sejam eleitos; quais as influências sofrerá uma empresa caso certa lei for aprovada; quais os impactos sofridos no mercado frente uma declaração de um político.
- **Popularidade** - Qual a opinião das pessoas em relação à empresa.
- **Expectativas** - Quais são as expectativas de outros investidores em relação à empresa.

Para executar a análise técnica, o investidor deve estudar os dados relacionados à empresa e ao ambiente em que ela está inserida e tentar fazer uma previsão de como suas ações irão se comportar.

Análise Técnica

Como definido por Edwards, Magee e Bassetti (2018), a análise técnica é o estudo do mercado por si só, sem considerar fatores externos. Tal abordagem consiste em estudar os dados históricos sobre as ações de uma empresa negociadas na bolsa de valores, como apresentado na Figura 1, e achar padrões. Estes padrões tendem a se repetir (LIEN, 2008) e, identificando tais comportamentos, é possível realizar previsões sobre as variações de uma determinada ação. A Figura 1 ilustra o comportamento de ações da Magazine Luiza MAGLU3 no período de junho de 2018 a junho de 2019, onde o eixo x representa o tempo e o y o preço da ação. A quando a ação sofre uma variação negativa ela é representada em vermelho e, quando ocorre uma variação positiva é representado em verde.

De modo simplista sem a utilização de métodos matemáticos e, com objetivo de exemplificar como se dá o funcionamento da análise técnica, é possível apontar alguns

Figura 1 – Magazine Luiza



Fonte: www.tradingview.com

padrões como mostra a Figura 2. Como representado pela flecha azul, nota-se que a ação está valorizando. Logo um investidor que pretende conseguir um retorno em um ano, por exemplo, poderia investir nesta ação. Entre as flechas vermelhas e amarelas referentes a Figura 2 podem ser notados *vales*, e entre as flechas amarelas e vermelhas, *picos*. Pode ser verificado que sempre depois de um *vale* existe um *pico*, que é seguido por outro *vale*. Portanto, uma das estratégias que um investidor de médio prazo poderia aplicar seria identificar quando esta ação estiver caindo por um tempo, e comprá-la assim que ela passar do *vale*. Por outro lado, quando ela chegar no *pico* é possível visualizar que pode haver um período de estabilidade, com pequena variação no preço, indicando que ela deve ser vendida, pois depois de um *pico* há uma descendente. O desafio é identificar se a ação realmente está saindo do *vale* e também se ela, de fato, chegou ao *pico*.

2.3 Elementos da Análise Técnica

Diversos trabalhos tentam prever como o mercado se comporta utilizando análise técnica: Malkiel (1999) analisa as vantagens e desvantagens da análise técnica; Edwards, Magee e Bassetti (2018) focam na identificação e análise de diferentes padrões e tendências; Connors e Connors (1998) demonstram como aplicar técnicas de *day trading*,

Figura 2 – Padrões MAGLU3



Fonte: www.tradingview.com

identificar alguns cenários e como agir em determinadas situações; Lien (2008) aborda como descobrir correlações entre ativos, quais os melhores momentos para se atuar no mercado e técnicas de gerenciamento de fundos de ações. Dentre as técnicas abordadas pelos autores citados duas delas chamam atenção, por ter um maior número de citações, são elas indicadores (subseção 2.3.1) e a teoria de Dow (subseção 2.3.2).

2.3.1 Indicadores

O comportamento do mercado de ações possui tendências e padrões os quais já foram observados por economistas e investidores, que desenvolveram meios para identificar tais comportamentos, os indicadores (CHEN; ROLL; ROSS, 1986). Colby e Meyers (1988) dizem que indicadores são moldados de forma que eles possam identificar padrões sem se preocupar com suas causas ou efeitos. Estes autores também mostram a eficiência destas técnicas aplicando-as em determinados períodos passados e mostrando como os indicadores teriam funcionado. Colby e Meyers (1988) classificam os diferentes tipos de indicadores nas seguintes categorias:

- **Indicadores de tendência** - Mostram em que direção o mercado está se movendo, pois mesmo com oscilações, se for definido um período de tempo, é possível notar que o mercado se move em um sentido.

- **Indicadores de momento** - São um modo de tentar prever a direção e consistência de uma tendência, a fim de identificar se ela vai se manter ou se alterar em um período de tempo.
- **Indicadores de volume** - Indicam quanto foi negociado no período, normalmente apontando a consistência dos movimentos. Caso forem negociados grandes volumes, tal tendência de movimentação tende a ser mais consistente.
- **Indicadores de volatilidade** - Expressam o quanto o preço de uma ação está variando com o tempo. Baixa volatilidade indica pouca variação nos valores e alta indica muita variação nos valores.

Com base nestas categorias de indicadores, e por vez combinando elas, são criados outros indicadores, estes quando aplicados geram retorno financeiro como demonstrado por Connors e Connors (1998). O lucro, gerado por tais métodos da análise técnica, podem fornecer um indicio de que a mesma é uma opção de analise do mercado.

2.3.2 Teoria de Dow

É possível observar que a média dos preços do mercado se move na mesma direção (EDWARDS; MAGEE; BASSETTI, 2018): caso um grande número de ações desvalorize-se é esperado que as outras ações também desvalorizem. Algumas ações, excepcionalmente e por um curto período de tempo, podem vir a se comportar de forma contrária à média do mercado mas, a longo prazo, tenderão a seguir o comportamento médio das demais. Este conceito é conhecido como *general market trend* ou tendência geral do mercado.

Charles Dow expressou estas tendências comuns em formas de médias, as quais foram apelidadas de médias de Dow-Jones (*Dow-Jones Averages*) ou indicadores de Dow-Jones (*Dow-Jones index*). Dow tenta mostrar as tendências e comportamentos do mercado de ações a partir de uma média de algumas ações pontualmente selecionadas, as quais deveriam representar o comportamento do mercado como um todo. Dow também criou uma média da indústria contemplando o preço de outras *commodities*.

Nestas tentativas de prever o comportamento do mercado, Charles Dow escreveu uma série de artigos para o *The Wall Street Journal* e, a partir da compilação destes artigos, é criada a Teoria de Dow (EDWARDS; MAGEE; BASSETTI, 2018) cujos aspectos centrais são apresentados abaixo.

- **As médias descontam tudo (Com algumas raras exceções)** - As médias são um reflexo da ação de milhares de investidores que, em sua maioria, têm acesso a informações atuais, estudam o mercado e fazem movimentações de forma lógica. Logo até desastres naturais podem ser refletidos, em questões de horas, quando observadas as médias.
- **Diferentes tendências** - O mercado possui diferentes tendências, que mostram que uma ação pode se comportar de forma diferente dependendo do espaço de tempo em que estiver sendo analisada.
- **Tendências Primárias** - São as tendências de uma ação em um longo espaço de tempo, por um ou mais anos, podendo ser ascendentes ou descendentes.
- **Tendências Secundárias** - São as tendências de uma ação em um intervalo médio, podendo variar de meses a semanas.
- **Tendências Menores** - São as tendências de uma ação em um curto espaço de tempo, como nas últimas semanas ou dias.

Uma determinada ação pode ter suas ações em ascendência na semana (tendência menor), decaindo nos últimos meses (tendência secundária), e ascendendo no último ano (tendência primária). Dow também mostra que estas tendências possuem fases e comportamentos distintos, dependendo da direção em que o valor de mercado da ação, que apresenta a tendência, se move.

- **Mercado do touro** - Tendências ascendentes possuem, geralmente, três fases:

Acumulação : é a primeira fase, onde os investidores começam a comprar ações não valorizadas; esses títulos, não possuem muita variação e, normalmente, os relatórios financeiros destas ações são ruins. Esta ação apresenta uma tendência menor, levemente ascendente.

Segunda fase : é o estágio onde as ações começam a se valorizar, a empresa começa a gerar lucros e bons relatórios financeiros; as ações valorizam rapidamente e de forma constante nesta fase.

Terceira fase : neste ponto todos os relatórios de finanças da empresa são bons; as ações atingiram um pico em seus valores; picos e vales momentâneos começam a aparecer.

- **Mercado do urso** - Assim como nas tendências ascendentes, as descendentes também apresentam três fases.

Distribuição : ela ocorre em paralelo ao final da terceira fase do mercado do touro.

Nesta fase é possível observar que as ações atingiram um valor alto e as chances para lucro são baixas neste ponto.

Segunda fase : as notícias e especulações são desfavoráveis à ação. Investidores começam a vender de forma urgente suas ações. Uma pequena descendente nos valores rapidamente se torna uma linha quase vertical e o preço decai.

Terceira fase : a descendência das ações diminui sua velocidade, porém, ainda continua. Não são muito noticiadas informações sobre esta ação.

- **Dois indicadores devem se confirmar** - Este princípio diz que não é possível constatar uma tendência analisando apenas um indicador. Sempre que observada uma tendência ocorrendo, descrita por um indicador, é recomendado observar o comportamento dos outros indicadores e verificar se eles estão se movendo na mesma direção. Como descrito no começo deste subcapítulo, “o mercado se move unido”, logo se constatado este tipos de movimentação contrária, em diferentes indicadores, seja do mercado de touro ou urso, em apenas um indicador, não se deve assumir que é uma tendência, podendo ser apenas uma anomalia.
- **Apenas o preço de fechamento é utilizado** - A teoria de Dow apenas utiliza do preço de fechamento em suas análises. As variações ocorridas durante o dia, altas e baixas, não são consideradas.

2.4 Séries temporais

De acordo com Box et al. (2015), séries temporais são uma sequência de dados, coletados ao longo de um determinado período. LeBaron, Arthur e Palmer (1999) explicam que o mercado de ações pode ser descrito como um conjunto de séries temporais, onde cada ação pode ser representada como uma série temporal.

Ao longo dos anos técnicas que tentam modelar aproximação para o comportamento de séries temporais foram desenvolvidas (BOX et al., 2015; ZHANG, 2003; AZOFF, 1994; WEIGEND, 2018). Azoff (1994) mostra que com o uso de técnicas de aprendizado de máquina, como RNA (Rede Neural Artificial), é possível prever parcialmente alguns casos de séries temporais, e isto pode ser apoiado por Hiransha et al. (2018), que conseguiram prever o comportamento de ações do *Bank of America* com uma taxa média de acerto até 95%; Moghaddam, Moghaddam e Esfandyari (2016), que obtiveram 93% de precisão na previsão de ações da (*National Association of Securities Dealers*

Automated Quotations) NASDAQ; e Sezer, Ozbayoglu e Dogdu (2017) que chegaram a um lucro de 11,93% com seu método que fazia uso de RNA.

2.5 Aprendizado de Máquina

Witten et al. (2016) explica que aprender é adquirir o conhecimento sobre algo, por estudo, experiência ou por ensinamentos de outro. É possível definir o aprendizado de máquina como o ato de fornecer à máquina dados, que seria o conhecimento; e um método que mostre como aprender os padrões expressos nestes dados. Shalev-Shwartz e Ben-David (2014) classificam os mais populares métodos de aprendizado de máquina em dois grupos, aprendizado supervisionado e não supervisionado. Shalev-Shwartz e Ben-David (2014) também mencionam que não existem apenas estes dois tipos de aprendizado de máquina, citando o aprendizado por reforço como exemplos de método que não se encontra em nenhuma das duas categorias.

Aprendizado supervisionado

Como descrito por LeCun, Bengio e Hinton (2015), no aprendizado supervisionado são fornecidos dados à máquina e a saída esperada, que possui uma conexão com o modo que os dados de entrada se relacionam. É desejado que o método de aprendizado supervisionado encontre uma relação entre as entradas fornecidas e a saída esperada. Contudo, isso normalmente não ocorre desde a primeira interação: é preciso de um método que mostre o quão distante o resultado alcançado é em relação ao resultado pretendido. Com este método o algoritmo então adapta seus parâmetros a fim de minimizar o erro entre o resultado obtido e o resultado esperado.

Dentre os métodos de aprendizado supervisionado (SAFAVIAN; LANDGREBE, 1991; GOODFELLOW; BENGIO; COURVILLE, 2016; JOACHIMS, 1998), irá ser abordado neste trabalho RNA.

Aprendizado supervisionado em Redes Neurais

A chave do aprendizado supervisionado são os métodos de ajuste dos pesos. Estes métodos permitem que, a partir de alguns parâmetros, seja possível ajustar os pesos das redes neurais para que as mesmas criem previsões mais próximas da realidade. Dos métodos de ajuste de peso é destacado *Back propagation*.

Back propagation

Wu (2017) explica que neste algoritmo é definido uma métrica de erro por $FuncErro(peso) = (1/2) * \sum_{TDS} (alvo - resultado)^2$ onde TDS são todos os dados.

Para saber o quanto se deve variar cada peso, de modo a aperfeiçoar a rede, é possível realizar a derivada parcial da *FuncErro* em função de cada peso individualmente $\frac{\partial FuncErro}{\partial peso_i} = \frac{\partial}{\partial peso_i} * (1/2) * \sum TDS(alvo - resultado)^2$ o resultado disto vai possibilitar o cálculo de erros, e o quanto se deve modificar os pesos e *bias* para obter melhores resultados, tanto para dados linearmente separáveis quanto não linearmente separáveis. Ao custo de fornecer, não sempre, o melhor resultado possível, mas sim o melhor resultado local possível.

Aprendizado não supervisionado

Oja (2002) define o aprendizado não supervisionado como o aprendizado puramente a partir da observação. Este método é utilizado quando não é conhecida a relação entre os dados de entrada. Então é fornecido a máquina um método que encontre uma relação entre as entradas de modo a gerar uma saída.

Nota-se que as técnicas de aprendizado não supervisionado podem vir a ser uma solução para diversos problemas clássicos, como a detecção de anomalias (ZANERO; SAVARESI, 2004), a auto organização (FRITZKE, 1994).


2.6 Redes Neurais Artificiais

Uma rede neural artificial (ROJAS, 2013) nada mais é do que uma rede de funções primitivas com um padrão de interconexões, como mostra a Figura 3. A função primitiva característica das redes neurais artificiais é chamada de neurônio artificial representada pela Figura 4. Onde g é a função de que será responsável por relacionar os dados (X_n) e então passar para f . A função g é denominada função de agregação, geralmente é representada por $g = (\sum_{i=1}^n x_i w_i) + bias$, onde *bias* é uma constante de ajuste. E a função f , intitulada função de ativação (examinada na subseção 2.6.1), é a responsável por suavizar a saída do neurônio dada a entrada fornecida por g . Estes dados possuem um peso(w) associado a ele, este peso vai dizer o quanto o dado é relevante para a saída.

2.6.1 Funções de ativação


A função de ativação tem como o objetivo atenuar a saída do neurônio, dada uma entrada fornecida pela função de agregação (LECUN et al., 2012). Existem inúmeros modelos para realizar tais tarefas, uma solução simples seria usar um modelo linear re-

Figura 3 – Rede Neural Artificial



Fonte: Rojas (2013)

Figura 4 – Neurônio artificial



Fonte: Rojas (2013)

presentado pela função $y = ax + b$, e na Figura 5 (A), que dada uma entrada fornecida pela função de agregação, é transposta para saída.

Contudo, as funções lineares não conseguem mapear comportamentos não lineares, e quando colocadas em uma rede de múltiplas camadas, elas não apresentam grandes vantagens, pois, múltiplas funções lineares, matematicamente, possuem o mesmo comportamento de uma função linear. Para contornar estes problemas, Nielsen (2015) propõe a utilização de funções de ativação não lineares como a sigmóide e tangente hiperbólica.

Sigmóide

A função de ativação sigmóide $S(x) = \frac{1}{1+e^{-x}} = \frac{e^x}{e^x+1}$, representada na Figura 5 (B), possui uma transição suave, evitando que anomalias, decorrentes de um aumento abrupto dos pesos ocorram. Esta função também tem os limites entre zero e um, o que normaliza as saídas automaticamente.

Tangente hiperbólica

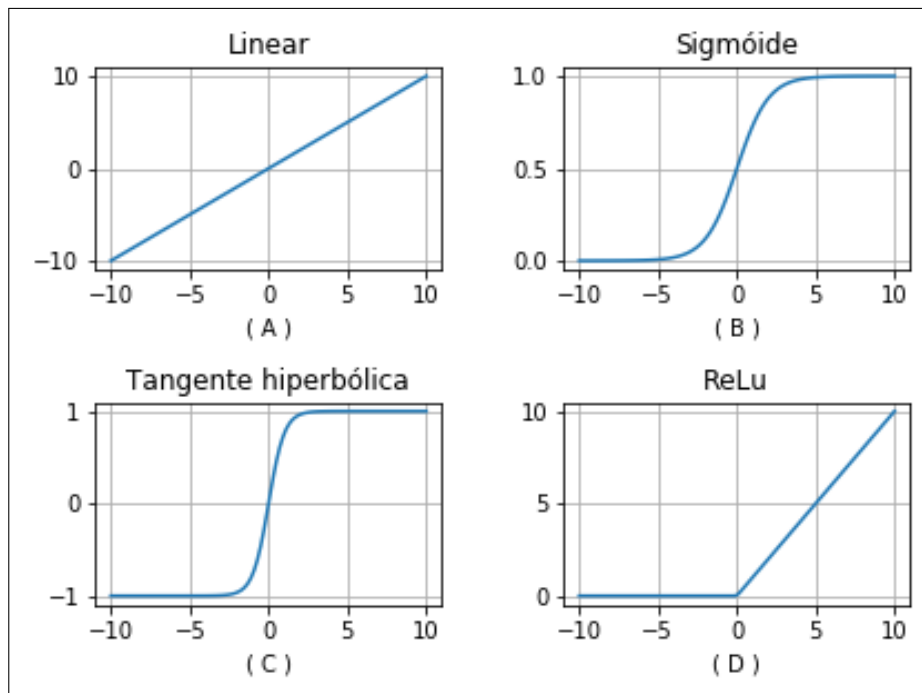


Figura 5 – Funções de ativação

Fonte: autor

A função de ativação tangente hiperbólica $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$, representada na Figura 5 (C), possui características semelhantes a sigmóide, com a vantagem de possuir o zero centralizado. O zero centralizado faz com que a derivada da função tangente hiperbólica no intervalo de menos um a um possua um alcance maior do que a derivada da função sigmóide do intervalo de zero a um, providenciando um gradiente mais robusto (LECUN et al., 2012).

(Rectified Linear Activation Unit) ReLu

Kuo (2016) demonstra que, em alguns tipos de redes neurais como as convolucionais, a função (Rectified Linear Activation Unit) ReLu $f(x) = x^+$, representada na Figura 5 (D), obtém um melhor desempenho. A ReLu retorna o valor da entrada para toda entrada positiva positivos e zero para entradas negativos. Ela combina a vantagem de uma função linear, que é o baixo custo computacional, sem ter as desvantagens de ser linear.

2.7 Arquiteturas de redes neurais

Goodfellow, Bengio e Courville (2016) descrevem dois diferentes tipos de arquiteturas de redes neurais artificiais: Redes neurais *feedforward*, dentre a qual se encontram


os as Redes *deep feedforward* e Redes Neurais Convolucionais; e Redes Neurais Recorrentes.

2.7.1 Feedforward

Uma rede neural *feedforward* (GOODFELLOW; BENGIO; COURVILLE, 2016) é aquela em que toda a comunicação entre entradas e saídas se move apenas em uma direção, sendo que cada neurônio só se comunica com neurônios da camada seguinte e nunca com neurônios de camadas anteriores ou da mesma camada. Quando adicionadas múltiplas camadas a uma rede *feedforward* é obtida uma *deep feedforward network* ou MLP (*multilayer perceptrons*).

Rojas (2013) mostra que ao adicionar múltiplas camadas de neurônios à RNA sua capacidade de identificar atributos, que caracterizam o problema, pode ser ampliada. A Figura 6 ilustra uma RNA *feedforward* onde cada neurônio recebe informações, as transforma e passa para os neurônios da próxima camada, modificando as informações a cada interação.

Figura 6 – Rede Neural Artificial de múltiplas camadas



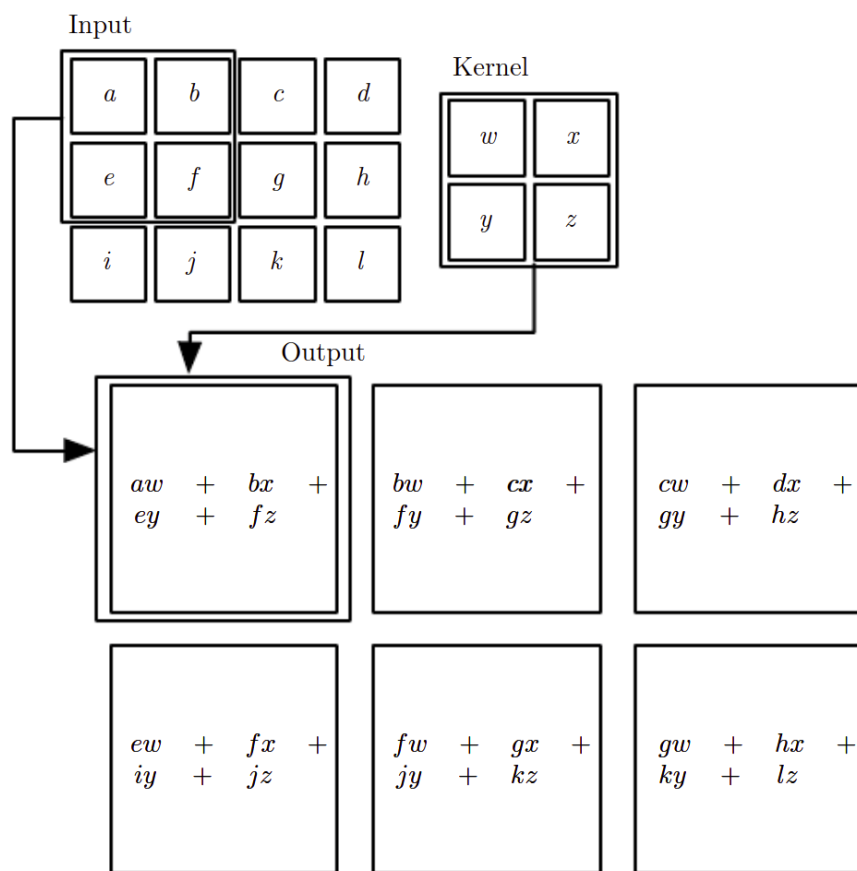
Fonte: Rojas (2013)

Redes Neurais Convolucionais

LeCun, Bengio e Hinton (2015) e Goodfellow, Bengio e Courville (2016) definem *Convolutional Neural Network* (CNN) como redes neurais *feedforward* com ao menos uma camada convolucional. Esta camada possui a característica de reduzir a dimensão da entrada, além ser mais preciso em capturar padrões dispersos, quando comparado com uma rede *feedforward* convencional. Além das camadas convolucionais, também é comum as CNN implementarem camadas de *pooling* e *flattening*.

A primeira camada de uma CNN consiste no uso de um *kernel*, que pode ser abstraído como uma matriz de padrões, que aplicado a uma entrada vai mapear os padrões dela, e gerar um mapa de padrões. Isto é melhor exemplificado na Figura 7 onde, dada um entrada (*Input*), aplica-se um *kernel*, o qual avança de posição a posição até ter passado por toda entrada, mapeando os padrões e reduzindo a dimensionalidade da entrada. Este avanço é comumente de um em um, contudo ele pode ser mudado. *Stride* é o nome do parâmetro que controla a quantidade de espaços que o *kernel* vai se mover por interação.

Figura 7 – Funcionamento do *Kernel*



Fonte: Goodfellow, Bengio e Courville (2016)

A segunda camada de uma rede convolucional, geralmente, é a camada de *pooling* que, de acordo com Goodfellow, Bengio e Courville (2016), tem o propósito de diminuir o número de parâmetros a serem computados e reduzir *overfitting*. *Overfitting* acontece quando um modelo decora um conjunto de treinamento e obtém bom desempenho, quando testado neste conjunto. Contudo o modelo não consegue obter o mesmo desempenho quando aplicado a dados do conjunto de teste. Uma das funções de *pooling*

mais populares, a *max pooling*, reduz o tamanho do mapa de padrões criando um novo mapa menor e o populando com o maior elemento de cada vizinhança.

A terceira e quarta camada são respectivamente as camadas de *flattening* e *feedforward*. Caso a entrada esteja representada em mais de uma dimensão, é a camada de *flattening*, que converte os dados para um vetor de uma dimensão. A camada *feedforward* utiliza o vetor da camada anterior como entrada de uma rede neural *feedforward*.

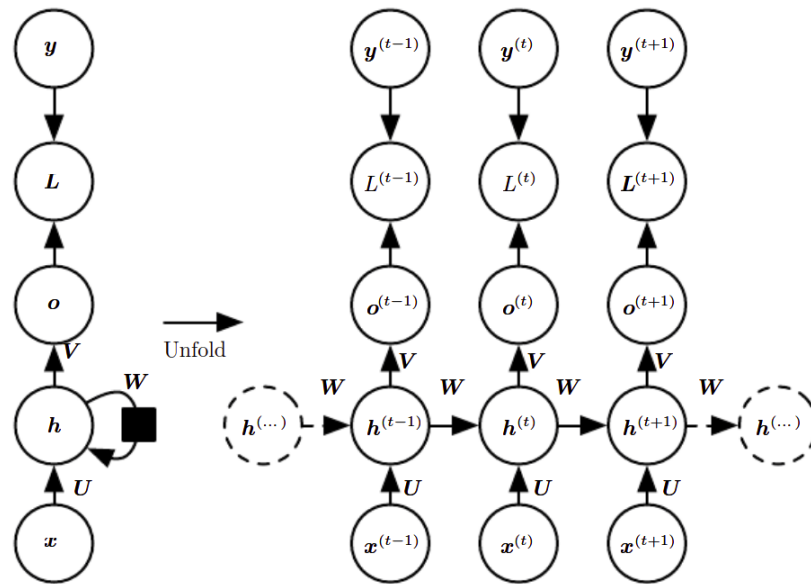
Na segunda camada, outra alternativa para contornar *overfitting* é a utilização da técnica de *dropout*, que não é uma técnica exclusiva de CNN podendo ser aplicada a todas RNA. Esta técnica desabilita uma porcentagem dos neurônios durante o período de treinamento da rede. Em seguida, atualiza os pesos de cada neurônio que estava ligado e troca o subconjunto de neurônios que vai ser desligado, repetindo o processo até finalizar o treinamento (SRIVASTAVA, 2013). A utilização de *dropout* tende a aumentar a precisão do modelo, quando o conjunto de dados utilizado para treinamento tem característica de gerar *overfitting*. Isso se dá pois, ao desligar os neurônios durante o processo de aprendizagem, diminui a probabilidade de entradas semelhantes, ou iguais, sejam utilizadas pelo mesmo neurônio múltiplas vezes e causem *overfitting*.

2.7.2 Redes Neurais Recorrentes

Conforme Goodfellow, Bengio e Courville (2016), assim como as CNN, as Redes Neurais Recorrentes, ou RNN (*Recurrent Neural Network*), são especializadas no processamento de dados com dependências espaciais. Como representada na Figura 8, o fluxo de dados nas redes recorrentes não é unidimensional, como nas *feedforward*, permitindo que um determinado valor de entrada seja relevante para processar a saída relativa ao tempo t como ao tempo $t - 1$. As RNN são especializadas no processamento de dados com dependências espaço-temporais especificamente. Esta capacidade é obtida pelo modo como a rede é projetada. Enquanto em uma rede *feedforward* os neurônios de uma camada (c) só serão alimentados pelos neurônios da camada anterior ($c - 1$) e apenas alimentarão os neurônios da camada posterior ($c + 1$), nas RNN os neurônios de uma camada (c) podem alimentar neurônios da mesma camada (c) e da próxima camada ($c + 1$).

A realimentação faz com que as RNN possuam uma espécie de memória, guardando informações passadas e levando-as em conta no processamento de informações futuras, dando a elas a capacidade de gerar diferentes saídas com uma mesma entrada, de acordo com o contexto da entrada (GERS; SCHRAUDOLPH; SCHMIDHUBER, 2002).

Figura 8 – Redes Neurais Recorrentes



Fonte: Rojas (2013)


Contudo, estas redes possuem muitas vezes uma adversidade, que são as dependências de longo prazo. O problema das dependências de longo prazo se dá quando uma rede atrela demasiada relevância, coloca peso alto, em uma entrada que está distante do contexto atual, e não deveria mais ser relevante, ou seja, o prazo em que aquela informação era relevante já extrapolou (LIN et al., 1996). Tentando contornar este problema, em 1997, Hochreiter e Schmidhuber publicaram a proposta de uma nova rede a *Long Short-Term Memory* (LSTM) (HOCHREITER; SCHMIDHUBER, 1997).

Long Short-Term Memory

As LSTM foram desenvolvidas especificamente para contornar o problema das dependências de longo prazo. Sua ideia principal é a criação de uma série de caminhos que filtram os dados mais relevantes, combinando as novas entradas com as saídas passadas. O funcionamento da LSTM é ilustrado pela Figura 9 e explicado a seguir.

Na camada *forget layer* são comparadas a saída passada (*recurrent*) com a entrada atual (*input*) e é decidido o quanto daquela informação deve ser mantida. Isto é feito através de uma função sigmóide (θ) que, dada as entradas, retorna valores (f) entre 0 e 1, sendo 0 sem relevância e um totalmente relevante. O mesmo processo coisa é feito na camada *input gate* e o resultado é representado por i . A camada *block input* tem o objetivo de ajudar a regularizar a rede, nela os valores de entrada atual e saída passada são dados de entrada para uma função de ativação g que, normalmente, é \tanh e sua saída é z . O

Figura 9 – LSTM



Fonte: Greff et al. (2016)

novo estado da célula LSTM (c) é calculado da seguinte forma: $c = f * c(t - 1) + it * zt$ onde t é o tempo atual e $t - 1$ é o tempo passado; em seguida a saída é passada por uma função de ativação h , que geralmente é \tanh . O valor de c após a função de ativação é então multiplicado por o , que é a saída de uma função sigmóide com as mesmas entradas das outras funções sigmóides, e isto resultará na saída de um bloco LSTM.

De forma enxuta, a rede consiste em portas de entrada, representados na imagem por *input gates*; célula de estado, *cell*, que remove ou adiciona informações com auxílio dos portões; camada de esquecimento, *forget layer*, porta que decide qual fração das informações serão mantidas ou esquecidas e portas de saída, *output gate*, que retorna a saída da rede (GREFF et al., 2016).¹

2.7.3 Otimizando *Hyper* parâmetros

Os *hyper* parâmetros são valores definidos antes de se iniciar o processo de treinamento dos modelos de aprendizado de máquina (GREFF et al., 2016). De acordo com Reimers e Gurevych (2017), a seleção de *hyper* parâmetros é um diferencial das redes neurais consideradas o estado da arte. Devido a quantidade de *hyper* parâmetros possíveis: número de camadas, número de neurônios em cada camada, função de ativação utilizada, uso ou não uso de *dropout*, entre outros, tornam a seleção de *hyper* parâmetros uma

¹As flechas azuis e *peepholes* ilustrados na imagem fazem parte das propostas de (GREFF et al., 2016) e não serão abordadas neste trabalho.


tarefa que exige alta demanda processamento computacional. Para contornar este problema, heurísticas foram desenvolvidas (FEURER; SPRINGENBERG; HUTTER, 2015). Bergstra et al. (2011) discutem três heurísticas de otimização de *hyper* parâmetros, das quais duas são sequenciais e baseadas em algoritmos gulosos e de *grid search*, e a remanescente utiliza estratégia de busca aleatória por força bruta. Eles demonstram, através de experimentos com múltiplos conjuntos de dados, que a estratégia de busca aleatória obtém resultados inferiores as estratégias sequenciais na busca de *hyper* parâmetros de uma RNA profunda. Eles também apontam que, em uma busca totalmente automatizada, não é conclusivo qual dos algoritmos sequenciais é melhor, contudo, quando utilizados junto com busca manual, o *grid search* foi o que obteve melhor resultado.

A *Grid search* é caracterizada pela escolha prévia de um conjunto fixo de *hyper* parâmetros e a escolha de um subconjunto de valores, que estes parâmetros irão assumir. No caso de redes neurais, são treinados modelos contendo cada uma das combinações dos *hyper* parâmetros no subconjunto e, em seguida, são obtidos os desempenhos de cada modelo. O desempenho de cada modelo pode ser obtido pelo cálculo de uma, ou mais, das fórmulas encontradas na seção 2.8. É então selecionado o conjunto de *hyper* parâmetros que obteve melhor desempenho para que uma nova busca seja realizada. Esta nova busca será feita com os valores de *hyper* parâmetros de um espaço próximos ao de melhor desempenho.

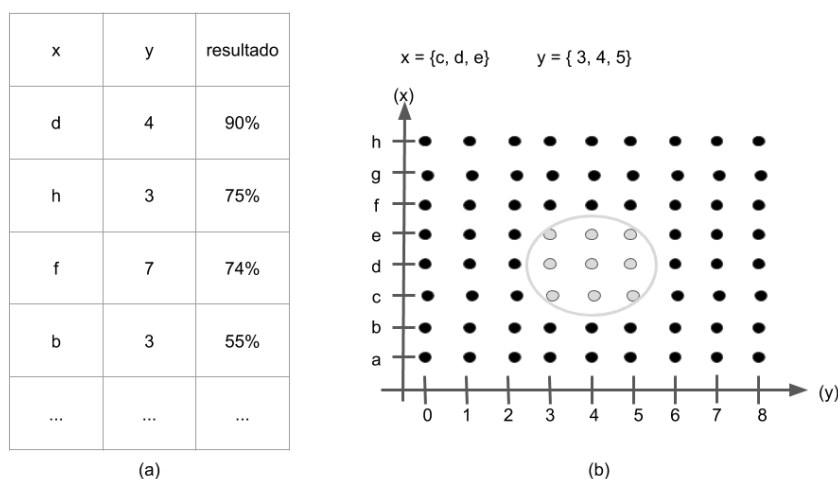
É possível ilustrar a *Grid search* com a Figura 10(a), onde os círculos pretos representam todos os *hyper* parâmetros possíveis; a escolha do subconjunto neste exemplo é mostrada no canto superior da Figura 10(a), e os *hyper* parâmetros que vão ser testados são ilustrados pela Figura 10(b) como círculos cinzas. Os resultados dos desempenhos serão salvos em uma tabela, como a ilustrada pela Figura 11(a); e a seleção de um novo subconjunto de valores de teste pode ser ilustrada pelos valores contidos dentro do círculo cinza da Figura 11(b).

2.8 Formas de avaliar resultados

Em um trabalho científico os resultados devem ser avaliados de forma clara e que possibilite a compreensão de como aqueles valores foram obtidos e, quando possível, utilizando métricas semelhantes aquelas encontradas em trabalhos correlatos (PRODANOV; FREITAS, 2013). Alguns dos métodos para analisar o desempenho de modelos de regressão são: Erro Quadrático Médio (EQM), Raiz do Erro Quadrático Médio (REQM),

Figura 10 – *Grid Search*

Fonte: Próprio autor (2020)

Figura 11 – *Grid Search 2*

Fonte: Próprio autor (2020)

Coeficiente de Determinação (R^2) e Erro Médio Percentual Absoluto (EMPA).

EQM e REQM

As medidas EQM e REQM, calcula a distância dos resultados preditos dos resultados esperados, logo quanto mais próximo de zero maior será a semelhança dos dados preditos (y) e dados esperados (x) (DEAKIN; KILDEA, 1999). São elas representadas pelas formulas $EQM = \left(\frac{1}{n}\right) \sum_{i=1}^n (y_i - x_i)^2$ e $REQM = \sqrt{\left(\frac{1}{n}\right) \sum_{i=1}^n (y_i - x_i)^2}$, onde n é a quantidade total de amostras e i é o indicativo de cada amostra.

R^2

A medida R^2 quantifica o quão próximo os resultados preditos estão do resultado

esperado, sendo que quanto mais próximo de 1 mais perto os resultados se encontram dos valores esperados (MOGHADDAM; MOGHADDAM; ESFANDYARI, 2016). A formula a seguir descreve a equação, $R^2 = 1 - \frac{\sum_{i=1}^n (y_i - x)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$, onde y_i é o valor da amostra, x é o valor previsto e \bar{y} é a média das observações, n é o número de observações e i é o indicativo de cada observação.

EMPA

Este método retorna a taxa de erro médio absoluto, logo quanto mais próximo de zero menor será a taxa percentual absoluta de erro e melhor será o modelo (HASSAN; NATH; KIRLEY, 2007), outra forma de avaliar os resultados obtidos por esta métrica é proposto por Lewis (1982) na Tabela 1. Representado pela seguinte formula $EMPA = \frac{\sum_{i=1}^n \frac{|y_i - \bar{y}|}{y_i}}{n} * 100\%$ onde y_i representa a amostra, \bar{y} é o valor previsto e n é o número de amostras.

Tabela 1 – Interpretação de EMPA

EMPA	Interpretação
<10	Alta acurácia de predição
10-20	Boa Predição
20-50	Predição razoável
>50	Predição ineficaz

Fonte: Lewis (1982)

2.9 Trabalhos Correlatos

Para a busca dos trabalhos correlatos foi utilizado o *google scholar*, que leva aos repositórios da *Sciencedirect*, *Springer*, *ACM digital library* e também artigos publicados em revistas e eventos. Os termos utilizados para busca foram *stock market forecasting*, *machine learning* e a conjunção dos dois termos. Os trabalhos que mais se assemelham à ideia proposta neste são: Roondiwala, Patel e Varma (2017), Selvin et al. (2017), Moghaddam, Moghaddam e Esfandyari (2016), Hassan, Nath e Kirley (2007). Os critérios de similaridade considerados foram a utilização de RNA na predição de preços de ações pertencentes a mercados de renda variável. As principais características dos trabalhos citados são encontrados na Tabela 2 e, a seguir, é fornecida um breve descrição do que foi feito em cada um deles.

Roondiwala, Patel e Varma (2017) utilizam uma rede neural *LSTM* para prever o

Tabela 2 – Trabalhos correlatos

Trabalho	Técnicas	Métrica de avaliação	Resultado
Predicting stock prices using LSTM	LSTM	REQM	0,00859
Stock price prediction using LSTM, RNN and CNN-sliding window model	RNN	EMQ	0,0512
	LSTM		0,0531
	CNN		0,0498
Stock market index prediction using artificial neural network	MLP 4D	R2	0,9616
	MLP 9D		0,9622
A fusion model of HMM, ANN and GA for stock market forecasting	HMM	EMPA	1,69%
	ARIMA		1,16%
	Proposto		1,14%

Fonte: Próprio autor (2020)

comportamento de ações do NIFTY (*National Stock Exchange of India*), índice da bolsa de valores indiana composta por cinquenta ações, manipulando valores coletados no período de 2011 a 2016. Esta rede é composta de duas camadas LSTM com 128 e 64 neurônios respectivamente, e mais duas camadas densas, estas com 16 e 1 neurônio. Foram utilizadas como entrada para rede os valores de: preço de abertura, preço máximo, preço mínimo, preço de fechamento e volume, e retornando como saída o preço de fechamento do próximo dia. Um conjunto de múltiplas combinações de parâmetros foi testado e, o que demonstrou melhor desempenho, foi uma rede composta por: uma entrada sequencial, duas camadas de LSTM, uma camada densa com a função ReLu, e uma saída com a função de ativação linear.

Selvin et al. (2017) fazem um estudo de caso medindo o desempenho de três redes neurais: RNR, LSTM, CNN. Este estudo utilizou as seguintes informações para treinamento e teste: identificador, preço e volume da ação, coletados de minuto a minuto, utilizando o período de 1 Julho a 14 de Outubro do ano de 2014 como treinamento e, de 15 de Outubro até 28 de Novembro de 2014 para teste. Ambas as redes foram treinadas com conjuntos de 90 minutos tentando prever os próximos 10 minutos. Para este estudo três ações da NIFTY foram selecionadas: Infosys, TCS e Cipla. EMQ foi utilizado como medida de desempenho, onde CNN obtiveram melhores resultados descritos na Tabela 2.

Moghaddam, Moghaddam e Esfandyari (2016) fazem a análise de desempenho de duas diferentes configurações de redes neurais do tipo MLP, quando aplicadas à previsão do mercado de ações NASDAQ (*National Association of Securities Dealers Automated Quotations*). São utilizados 70 dias úteis para treinamento e 29 dias úteis para teste, compreendendo o período de 28 de Janeiro de 2015 a 18 de junho de 2015 e coeficiente de

determinação como métrica de desempenho. Primeiramente eles compararam as seguintes funções de ativação: função linear, sigmóide e tangente hiperbólica, em busca da que tenha melhor desempenho, com a tangente hiperbólica levando uma vantagem de 7% sobre suas concorrentes. Em seguida é buscada a melhor configuração de rede, referente a quantidade de camadas ocultas e número de neurônios, para atuar em dois diferentes cenários: na previsão de quatro dias a frente e na previsão de nove dias a frente. Na rede que tenta prever quatro dias, denominada na tabela MLP (4d), a melhor configuração, dentre as 16 testadas, obtém desempenho de R^2 igual a 0,9616, enquanto a que tenta prever nove dias, MLP (9d), tem R^2 igual a 0,9622.

Hassan, Nath e Kirley (2007) juntam três técnicas: HMM (*Hidden Markov Model*), utilizado para identificar padrões; algoritmos genéricos, para otimizar os padrões; e RNA, do tipo MLP, para agrupar os preços das ações. Utilizando um conjunto de três ações: Apple, IBM e Dell para treinar e avaliar os modelos, utilizando o período entre 10 Fevereiro de 2003 a 10 de Setembro de 2004 para treino e, 14 de Setembro de 2004 a 21 de Janeiro de 2005 para testes. Foram utilizados como entrada os cinco dias prévios e a saída esperada era o preço de fechamento do próximo dia, e foram comparadas utilizando a métrica EMPA o desempenho da técnica proposta pelos autores com HMM e ARIMA (*Autoregressive integrated moving average*), na qual a técnica proposta se saiu melhor com resultado de 1,14% .

Por estarem em diferentes métricas de avaliação os resultados dos trabalhos não podem ser diretamente comparados, com exceção dos trabalhos de Roondiwala, Patel e Varma (2017) e Selvin et al. (2017), na qual a métrica REQM se converte para EMQ caso elevada ao cubo.

3 METODOLOGIA

Neste capítulo é discutida a classificação desta pesquisa na seção 3.1. Na seção 3.2 são descritas quais foram as decisões que levaram a abordagem do problema; na seção 3.3 é apresentada a base de dados utilizada e como foram manipuladas as amostras; por fim as decisões referentes ao treinamento da rede neural, e o que ela se propõem a prever, é exposto na seção 3.4.

3.1 Classificação desta pesquisa

Segundo Prodanov e Freitas (2013), esta pesquisa é classificada como de natureza aplicada, pois gerará conhecimentos voltados a solucionar um problema específico, o desenvolvimento de uma aplicação que irá auxiliar na tomada decisões sob transições realizadas no mercado de ações. Do ponto de vista dos procedimentos, ela possui caráter experimental, visto que a partir das variáveis que moldam o problema e testes com diferentes tipos de métodos, buscou-se produzir uma solução. E da perspectiva da abordagem, é classificada como quantitativa, uma vez que retorna valores numéricos, quantificáveis, seus resultados podem ser classificados e analisados.

3.2 Material e Métodos

Como mostrado em Indicadores e Teoria de Dow, é possível notar que o mercado de ações possui padrões e tendências. O funcionamento de uma RNA se dá pelo reconhecimento de padrões e, a partir deles, realizar previsões. Logo se for configurada uma RNA para atuar no mercado de ações, é esperado que ela reconheça estes padrões. A Teoria de Dow também fornece suporte para utilizar uma análise puramente técnica.

A utilização do método de *deep learning* para predição do mercado de ações já foi explorada em outros trabalhos encontrados na literatura (HSU et al., 2016; SEZER; OZBAYOGLU; DOGDU, 2017; HIRANSHA et al., 2018; MENON et al., 2016; ZHANG, 2003). O método apresenta a vantagem de, não apenas, mapear comportamentos lineares, assim como outras técnicas de aprendizado de máquina, como também lidar padrões não lineares.

Para a escolha do período de tempo em que irá tentar realizar previsões, foram

tomados como referência Pan (2004), Raschke e Connors (1996), Farley (2000), eles utilizam janela de tempo igual ou inferior a cinco dias úteis para tomarem decisões sob um conjunto de ações. Destes estudos Pan (2004) justifica que é possível prever padrões de um curto espaço de tempo, até um dia, quando analisados períodos de inferiores a 5 dias.

3.3 Base de dados

Foram utilizados os dados fornecidos pela B3¹, que produz relatórios diários das ações, e outros papéis, que estão sob seu controle, e são referentes a os anos de 2015 a 2019. Destes relatórios serão utilizados os dados especificados na Tabela 3. A descrição de todos os dados, assim como um breve explicação de seu conteúdo, é encontrada em anexo.

As ações que serão utilizadas neste estudo, e seus códigos de negociação são: VALE3, ITUB4, BBDC4, PETR3, ABEV3. Estas ações foram escolhidas pois compõem alta porcentagem da B3 (9,86%, 9,64%, 8,66%, 5,47%, 4,75%) respectivamente, 45% do valor total da B3 no ano de 2019.

Tabela 3 – Características das amostras

Nome	Descrição
CODNEG	Código de negociação do papel
Abertura	Preço de abertura do mercado
Máx	Preço máximo do mercado
Mín	Preço mínimo do mercado
Fechamento	Preço de fechamento do mercado
Volume	Volume total de títulos negociados

Fonte: Próprio autor (2020)

Os dados utilizados também foram escalonados entre os valores de zero e um. A escalonagem não altera a variância da série temporal, e seu propósito, quando utilizada junto a técnicas de aprendizado de máquina, é a possibilitar que o modelo gerado não só preveja valores dentro de uma certa escala, e sim modele o sistema em termos de suas variações (MJOLNESS; SHARP; ALPERT, 1989). A realização da escalonagem também permite que uma RNA treinada com uma determinada ação X tente prever o comportamento de uma ação Y, pois ambas estarão na mesma escala.


¹http://www.b3.com.br/pt_br/market-data-e-indices/servicos-de-dados/market-data/historico/mercado-a-vista/series-historicas/

A fim de realizar o treinamento e validação, de ambas as propostas, os dados foram separados da seguinte forma, os anos de 2015 a 2018 foram utilizados para treinamento, enquanto o ano de 2019 para validação

3.4 Aprendizado de Máquina

Utilizando uma LSTM duas abordagens serão avaliadas. Tanto a abordagem 1 (Figura 12) quanto a abordagem 2 (Figura 13) receberão os mesmos valores de entrada, serão eles: volume de negociações, preço de abertura, preço de fechamento, valor máximo, e valor mínimo, todos estes valores referentes a cinco dias úteis. O que difere a abordagem 1 da 2 é o que elas tentam prever. A abordagem 1 utiliza os valores de cinco dias prévios, representados em amarelo na (Figura 12), para tentar prever o valor de fechamento do próximo dia, representado em verde; a abordagem 2 utiliza o valor dos cinco dias prévios, representados em amarelo na (Figura 13), para tentar prever o valor de abertura do próximo dia, representado em verde na (Figura 13).

Figura 12 – Abordagem 1



DIA	CODNEG	Volume	Abertura	Máx	Min	Fechamento
1	PETR3	38743683200	2541	2695	2510	2665
2	PETR3	34301979500	2665	2743	2628	2720
3	PETR3	29692290100	2724	2756	2707	2751
4	PETR3	45908102800	2756	2910	2755	2840
7	PETR3	35733482300	2865	2877	2811	2825
8	PETR3	26840840600	2851	2898	2851	2882
9	PETR3	21962974200	2873	2878	2835	2868
10	PETR3	18440856500	2859	2859	2825	2850
11	PETR3	17761292500	2828	2870	2811	2840


DIA	CODNEG	Volume	Abertura	Máx	Min	Fechamento
1	PETR3	38743683200	2541	2695	2510	2665
2	PETR3	34301979500	2665	2743	2628	2720
3	PETR3	29692290100	2724	2756	2707	2751
4	PETR3	45908102800	2756	2910	2755	2840
7	PETR3	35733482300	2865	2877	2811	2825
8	PETR3	26840840600	2851	2898	2851	2882
9	PETR3	21962974200	2873	2878	2835	2868
10	PETR3	18440856500	2859	2859	2825	2850
11	PETR3	17761292500	2828	2870	2811	2840

DIA	CODNEG	Volume	Abertura	Máx	Min	Fechamento
1	PETR3	38743683200	2541	2695	2510	2665
2	PETR3	34301979500	2665	2743	2628	2720
3	PETR3	29692290100	2724	2756	2707	2751
4	PETR3	45908102800	2756	2910	2755	2840
7	PETR3	35733482300	2865	2877	2811	2825
8	PETR3	26840840600	2851	2898	2851	2882
9	PETR3	21962974200	2873	2878	2835	2868
10	PETR3	18440856500	2859	2859	2825	2850
11	PETR3	17761292500	2828	2870	2811	2840

Fonte: Próprio autor (2020)

Ambas (Figura 12) e (Figura 13) também mostram a utilização de uma janela deslizante (VAFAEIPOUR et al., 2014), técnica utilizada para fornecer dados a rede durante o treinamento, nela os valores em amarelo representam as entradas e o valores em verde são as variáveis dependentes, que serão utilizadas pelo algoritmo de aprendizagem para determinar o quão próximo os resultados produzidos estão dos esperados. As flechas vermelhas são responsáveis por ilustrar a ordem de treinamento, inicialmente utilizando

Figura 13 – Abordagem 2



CODNEG	Volume	Abertura	Máx	Min	Fechamento
1PETR3	38743683200	2541	2695	2510	2665
2PETR3	34301979500	2665	2743	2628	2720
3PETR3	29692290100	2724	2756	2707	2751
4PETR3	45908102800	2756	2910	2755	2840
7PETR3	35733482300	2865	2877	2811	2825
8PETR3	26840840600	2851	2898	2851	2882
9PETR3	21962974200	2873	2878	2835	2868
10PETR3	18440856500	2859	2859	2825	2850
11PETR3	17761292500	2828	2870	2811	2840

CODNEG	Volume	Abertura	Máx	Min	Fechamento
1PETR3	38743683200	2541	2695	2510	2665
2PETR3	34301979500	2665	2743	2628	2720
3PETR3	29692290100	2724	2756	2707	2751
4PETR3	45908102800	2756	2910	2755	2840
7PETR3	35733482300	2865	2877	2811	2825
8PETR3	26840840600	2851	2898	2851	2882
9PETR3	21962974200	2873	2878	2835	2868
10PETR3	18440856500	2859	2859	2825	2850
11PETR3	17761292500	2828	2870	2811	2840

CODNEG	Volume	Abertura	Máx	Min	Fechamento
1PETR3	38743683200	2541	2695	2510	2665
2PETR3	34301979500	2665	2743	2628	2720
3PETR3	29692290100	2724	2756	2707	2751
4PETR3	45908102800	2756	2910	2755	2840
7PETR3	35733482300	2865	2877	2811	2825
8PETR3	26840840600	2851	2898	2851	2882
9PETR3	21962974200	2873	2878	2835	2868
10PETR3	18440856500	2859	2859	2825	2850
11PETR3	17761292500	2828	2870	2811	2840

Fonte: Próprio autor (2020)

os cinco primeiros dias como entrada e o sexto como variável independente, em seguida utilizando os valores do dia dois até o dia oito como entradas e dia nove como variável independente, e assim por diante, sempre aumentando um dia útil por iteração.

Os valores referentes a os *hyper* parâmetros serão obtidos através de uma *grid search*, técnica explicada na subseção 2.7.3. Devido a os testes, que envolvem o treinamento e validação de uma rede, consumirem certa quantidade de tempo, foram tomadas algumas decisões que irão impactar em uma menor abrangência na busca dos *hyper* parâmetros: o tamanho de *batch* e quantidade de *epoch* serão definidos como 16 e 100 respectivamente; A rede será otimizada utilizando apenas amostras de ações PETR3, sob a abordagem 1, as outras redes testarão apenas os melhores resultados de *hyper* parâmetros provenientes desta busca; não serão realizados múltiplos *grid search* a fim de refinar a busca. A métrica de avaliação de rede, para decidir qual o melhor conjunto de *hyper* parâmetros, será REQM e R2.

Os *hyper* parâmetros buscados serão: *Dropout*, Função de ativação, número de camadas e quantidade de neurônios em cada camada. Foram utilizados valores de *dropout* entre 20% e 50%, apenas nas ultimas camadas, como sugerido por Srivastava (2013). As funções de ativação sugeridas por Greff et al. (2016), *tanh* e *ReLU*, foram adotadas para teste. Os trabalhos de Greff et al. (2016) e Reimers e Gurevych (2017) foram tomados como base para escolha do número de neuros e camadas que seriam testados. Para avaliar qual conjunto de parâmetros obteve melhor desempenho serão utilizadas as medidas REQM e R2.

4 ABORDAGEM PROPOSTA

Este capítulo tem como objetivo apresentar os resultados e dados gerados por este trabalho, primeiramente na seção 4.1 é feita uma análise das amostras que serão utilizadas para treino e validação; na seção 4.2 são apresentados e discutidos os resultados do *grid search*, responsável por achar os parâmetros das redes; na seção 4.3 são mostrados os resultados que as diferentes redes obtiveram; por fim na seção 4.4 são apresentados os melhores resultados encontrados neste trabalho e feito um paralelo com os trabalhos correlatos.

4.1 Análise do conjunto de dados

Após os dados serem divididos em amostras de treinamento, referentes aos anos de 2015 a 2018 e amostras de validação, ano de 2019, foram extraídas informações que podem dar indícios da complexidade de prever as variações de determinada ação. A Tabela 4 informa a VM(variação média) e DPA(desvio padrão amostral) da variação de preços, para as amostras de treinamento e de validação, de cada ação. A tabela também informa o coeficiente de determinação R2 de cada ação quando utilizados o dia anterior e o posterior no ano de 2019. A utilização do coeficiente desta forma é equivalente a assumir que o valor de fechamento do dia anterior vai ser igual ao valor de fechamento do próximo dia.

Tabela 4 – Variações

Nome	DP validação	VM validação	DPA treino	VM treino	R2
PETR	0.014999	-0.000287	0.028316	-0.001245	0.8702
VALE	0.015868	-0.001114	0.027199	-0.000499	0.8153
ITUB	0.01472	-0.000236	0.016619	0.000203	0.8842
BBDC	0.014934	-0.000079	0.017781	0.000324	0.9627
ABEV	0.014405	0.00095	0.01199	0.000183	0.8935

Fonte: Próprio autor (2020)

4.2 Seleção de *Hyper* parâmetros

A seleção dos *hyper* parâmetros: número de camadas, quantidade de unidades LSTM em cada camada, função de ativação de entrada e saída da unidade LSTM e *dropout* foi feita através da técnica de *grid search*. Os 5 melhores resultados se encontram na Tabela 5, enquanto a busca completa se encontra no Apêndice A. Na primeira coluna, *Network*, é descrita a quantidade de camadas, e quantidade de unidades LSTM em cada camada; na coluna dois, *Dropout*, é exibido a quantidade de *Dropout* utilizada em cada camada; Na coluna três, *Activation Function*, é apresentado a função de ativação; e na quarta e quinta coluna contem os resultados de REQM e R2 respectivamente.

Tabela 5 – Grid Search

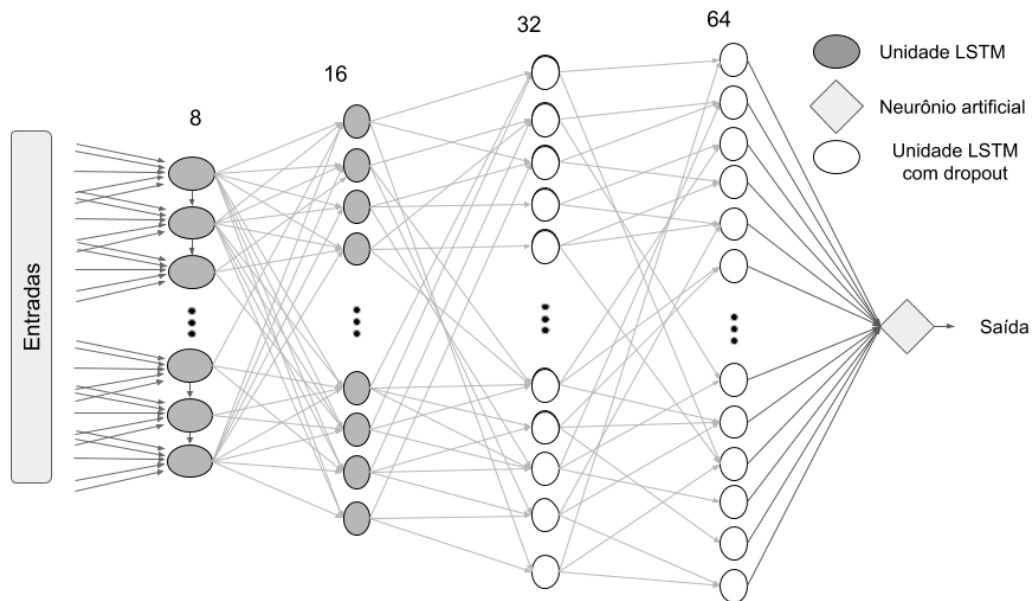
Network	Dropout	Função de ativação	REQM	R2
[8, 16, 32, 64]	[0, 0, 0.2, 0.5]	tanh	0.04453	0.955055
[16, 32, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.045502	0.953072
[8, 16, 32, 64, 128]	[0, 0, 0, 0.2, 0.2]	relu	0.045852	0.952347
[8, 16, 32, 64, 128]	[0, 0, 0.2, 0.2, 0.2]	relu	0.046222	0.951575
[8, 16, 32, 32, 64]	[0, 0, 0, 0.2, 0.2]	relu	0.046266	0.951483

Fonte: Próprio autor (2020)

Em seguida foram avaliadas as duas configurações de rede que obtiveram melhores resultados no *grid search*. A configuração da rede I pode ser ilustrada pela Figura 14 e possui cinco camadas de unidades LSTM, onde cada camada contem respectivamente 8, 16, 32 e 64 unidades LSTM. Dentro de uma mesma camada as unidades são conectadas entre si, e as saídas das unidades de uma camada são completamente conectadas com as entradas da próxima camada, isto ocorre em ambas as redes. A rede possui *dropout* de 20% e 50% em duas das ultimas camadas. Em ambas as redes as saídas da ultima camada são ligadas a um neurônio artificial, responsável por gerar a saída da rede e, a função de ativação de entrada e saída da unidade LSTM, assim como do neurônio artificial, é *tanh*.

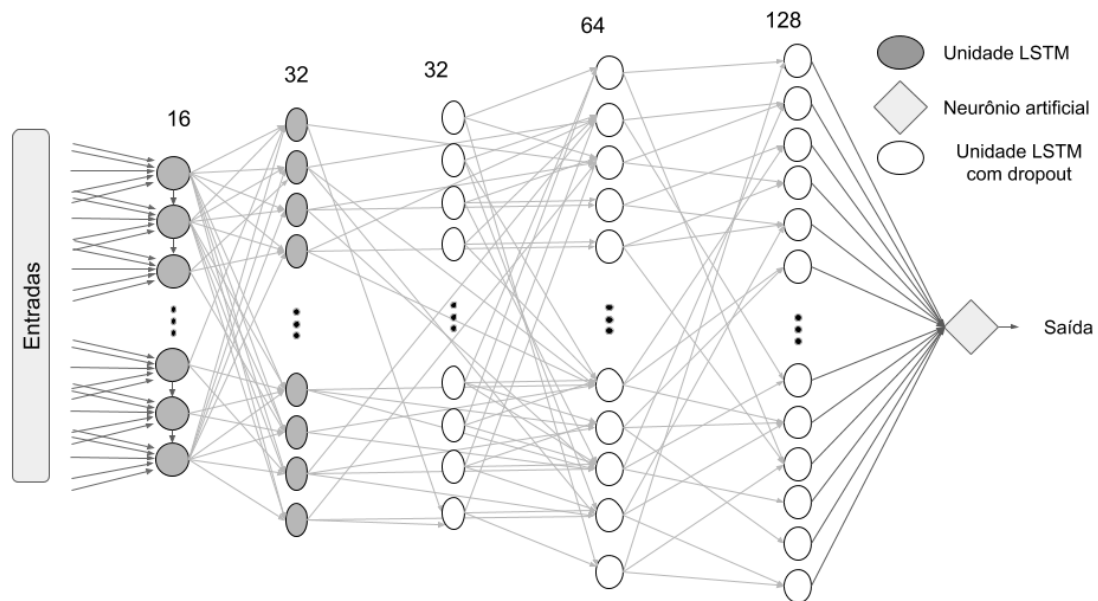
A configuração da rede II (Figura 15) possui cinco camadas de unidades LSTM, onde cada camada contem respectivamente 16, 32, 32, 64 e 128 unidades LSTM. A rede possui *dropout* de 20%, 30% e 50% respectivamente nas três ultimas camadas.

Figura 14 – Rede I



Fonte: Próprio autor (2020)

Figura 15 – Rede II



Fonte: Próprio autor (2020)

4.3 Resultados experimentais

Utilizando as configurações de rede encontradas na Subseção anterior foram realizados os treinamentos e validações de todas as amostras, os melhores resultados são

encontrados na Tabela 13 e representados graficamente pelas Figuras(16, 17, 18, 19, 20). A tabela com todos os resultados é encontrada no Apêndice B.

Figura 16 – *Predição AMBEV 2019*



Fonte: Próprio autor (2020)

Figura 17 – *Predição BBDC 2019*



Fonte: Próprio autor (2020)

Os melhores resultados foram encontrados nos modelos treinados e validados nas ações BBDC (Figura 18) com 0,99 de R2 na predição do preço de abertura e 0,98 de R2 no preço de fechamento. O modelo que obteve melhor desempenho quando comparado a diferença do seu coeficiente de determinação R2 com coeficiente da amostra, referente

Figura 18 – *Predição ITUB 2019*


Fonte: Próprio autor (2020)

Figura 19 – *Predição PETR 2019*

Fonte: Próprio autor (2020)

a Tabela 4, foi o da VALE (Figura 20) com ganho de aproximadamente 0.12 tanto na predição do preço de fechamento com no de abertura.

É possível que haja uma relação entre os desvio padrão e variações médias de cada ação e o desempenho dos modelos gerados pela RNA, pois esta amostra é a que possui menor variação média dentre as amostras de validação. Contudo a quantidade de ações que estão sendo analisadas neste trabalho não possibilita realizar afirmações sobre esta hipótese.

Figura 20 – *Predição VALE 2019*

Fonte: Próprio autor (2020)

Buscando examinar se os modelos criados são capazes de prever o comportamento de ações que não foram treinados, foi testado se os modelos treinados com amostras de uma certa ação seria apto a prever as saídas de outra ação, ao qual não foi treinado. Os resultados sob os preços de abertura são encontrados na Tabela 7 e de fechamento na Tabela 8.

Os resultados da predição de modelos treinados em outras ações apontam evidências de que as redes conseguem prever o comportamento de ações que não foram treinadas. É possível observar que alguns modelos obtiveram melhores resultados na predição das variações de ações que não foram treinados, quando comparados a modelos que foram treinados com amostras do mesmo título. Modelos que obtiveram melhores resultados prevendo o preço de abertura representado na Tabela 9, já os que obtiveram melhores resultados no preço de fechamento se encontram na Tabela 10. Em ambas as tabelas a primeira coluna, modelos, representa o título das amostras utilizadas para treinar o modelo, já na segunda coluna, ação, são as amostras de validação. R2 MO é o coeficiente de determinação que o modelo gerado com amostras do mesmo título obteve, e R2 ME é o coeficiente do modelo treinado com amostras de outro título.

4.4 Comparação com trabalhos correlatos

A comparação de resultados encontrados neste trabalhos com outros, que utilizaram diferentes amostras, diferentes períodos de tempo e diferentes mercados não é ideal, pois eles não serão avaliados em iguais condições. Idealmente as comparações ocorreriam no mesmo período de tempo, mesmo mercado e com as mesmas ações. Contudo, a implementação dos métodos propostos nos outros trabalhos e a realização destes testes no mesmo cenário não são o objetivo deste trabalho.

Com o objetivo de mostrar como o desempenho do método proposto neste trabalho, que atua no mercado da B3, se compara a outros trabalhos atuando em seus mercados específicos foram comparados os melhores resultados deste trabalho com os trabalhos correlatos. Os resultados desta comparação se encontram na Tabela 11.

Tabela 6 – Avaliação das ações

Nome	Feature	Network	Dropout	Função de ativação	REQM	EQM	R2	EMPA/100
PETR	Fechamento	[8, 16, 32, 64]	[0, 0, 0.2, 0.5]	tanh	0.051781	0.002681	0.939228	0.077717
PETR	Abertura	[8, 16, 32, 64]	[0, 0, 0.2, 0.5]	tanh	0.057561	0.003313	0.911918	0.092292
VALE	Fechamento	[8, 16, 32, 64]	[0, 0, 0.2, 0.5]	tanh	0.050496	0.00255	0.936329	0.070754
VALE	Abertura	[16, 32, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.049643	0.002464	0.931161	0.065955
ITUB	Abertura	[8, 16, 32, 64]	[0, 0, 0.2, 0.5]	tanh	0.052889	0.002797	0.943377	0.070486
ITUB	Fechamento	[16, 32, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.039386	0.001551	0.959925	0.058971
BBDC	Fechamento	[16, 32, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.031138	0.00097	0.987111	0.053008
BBDC	Abertura	[16, 32, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.027462	0.000754	0.990253	0.050674
ABEV	Abertura	[8, 16, 32, 64]	[0, 0, 0.2, 0.5]	tanh	0.0434	0.001884	0.94057	0.072592
ABEV	Fechamento	[16, 32, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.040249	0.00162	0.959839	0.082764

Fonte: Próprio autor (2020)

Tabela 7 – Predição de modelos em ações distintas (Abertura)

Modelo	Ação	REQM	EQM	R2	EMPA /100
PETR	VALE	0.04984	0.002484	0.930612	0.067788
PETR	ITUB	0.046863	0.002196	0.955545	0.0618
PETR	BBDC	0.027463	0.000754	0.990252	0.049629
PETR	ABEV	0.054368	0.002956	0.906738	0.093274
VALE	PETR	0.067865	0.004606	0.877561	0.110229
VALE	ITUB	0.05309	0.002819	0.942946	0.069379
VALE	BBDC	0.026784	0.000717	0.990728	0.048447
VALE	ABEV	0.061413	0.003772	0.881003	0.106845
ITUB	PETR	0.060275	0.003633	0.903418	0.095837
ITUB	VALE	0.053439	0.002856	0.920229	0.072193
ITUB	BBDC	0.028118	0.000791	0.989781	0.050768
ITUB	ABEV	0.059319	0.003519	0.888977	0.103172
BBDC	PETR	0.071849	0.005162	0.862766	0.112197
BBDC	VALE	0.051857	0.002689	0.924883	0.067859
BBDC	ITUB	0.070717	0.005001	0.898771	0.092597
BBDC	ABEV	0.068211	0.004653	0.8532	0.116659
ABEV	PETR	0.050233	0.002523	0.932918	0.073646
ABEV	VALE	0.045039	0.002029	0.943336	0.055071
ABEV	ITUB	0.046801	0.00219	0.955663	0.060461
ABEV	BBDC	0.027747	0.00077	0.990049	0.04841

Fonte: Próprio autor (2020)

Tabela 8 – Predição de modelos em ações distintas (Fechamento)

Modelo	Ação	REQM	EQM	R2	EMPA/100
PETR	VALE	0.052439	0.00275	0.931333	0.07262
PETR	ITUB	0.04843	0.002345	0.939409	0.075302
PETR	BBDC	0.033078	0.001094	0.985455	0.053912
PETR	ABEV	0.046111	0.002126	0.947289	0.094294
VALE	PETR	0.047847	0.002289	0.948111	0.076839
VALE	ITUB	0.039767	0.001581	0.959147	0.064604
VALE	BBDC	0.030242	0.000915	0.987842	0.051901
VALE	ABEV	0.042904	0.001841	0.954365	0.09451
ITUB	PETR	0.055999	0.003136	0.928923	0.095417
ITUB	VALE	0.049005	0.002402	0.940032	0.070244
ITUB	BBDC	0.032481	0.001055	0.985974	0.054139
ITUB	ABEV	0.04819	0.002322	0.942428	0.11207
BBDC	PETR	0.045194	0.002043	0.953705	0.065328
BBDC	VALE	0.050388	0.002539	0.9366	0.069931
BBDC	ITUB	0.038658	0.001494	0.961392	0.060715
BBDC	ABEV	0.03684	0.001357	0.966353	0.066517
ABEV	PETR	0.048937	0.002395	0.94572	0.077923
ABEV	VALE	0.0497	0.00247	0.93832	0.066345
ABEV	ITUB	0.040432	0.001635	0.957769	0.061913
ABEV	BBDC	0.032872	0.001081	0.985635	0.056925

Fonte: Próprio autor (2020)

Tabela 9 – Modelos com melhores resultados que original (Abertura)

Modelo	Ação	R2 MO	R2 ME	(MO – ME)
PETR	ITUB	0.943377	0.955545	-0.012168
ABEV	VALE	0.931161	0.943336	-0.012175
ABEV	PETR	0.911918	0.932918	-0.021

Fonte: Próprio autor (2020)

Tabela 10 – Modelos com melhores resultados que original (Fechamento)

Modelo	Ação	R2 MO	R2 ME	(MO – ME)
ITUB	VALE	0.936329	0.940032	-0.003703
BBDC	PETR	0.939228	0.953705	-0.014477
BBDC	VALE	0.936329	0.9366	-0.000271
BBDC	ITUB	0.959925	0.961392	-0.001467

Fonte: Próprio autor (2020)

Tabela 11 – Comparação com trabalhos correlatos

Trabalho	Técnicas	Métrica de avaliação	Resultado do trabalho correlato	Resultado deste trabalho
Predicting stock prices using LSTM	LSTM	REQM	0,00859	0.027462
Stock price prediction using LSTM, RNN and CNN-sliding window model	RNN	EMQ	0,0512	0,000754
	LSTM		0,0531	
	CNN		0,0498	
Stock market index prediction using artificial neural network	MLP 4D	R2	0,9616	0,990253
	MLP 9D		0,9622	
A fusion model of HMM, ANN and GA for stock market forecasting	HMM	EMPA	1,69%	5,07%
	ARIMA		1,16%	
	Proposto		1,14%	

Fonte: Próprio autor (2020)

5 CONCLUSÕES

Neste trabalho foi tratado o mercado de ações (Seção 2.1) e os diferentes tipos de métodos de previsão de retorno (Seção 2.2) deste mercado. Na sequência foi explorada a análise técnica (Seção 2.3), um dos métodos de previsão de retorno e, discutido como modelar o mercado de ações em séries temporais (Seção 2.4). Foram também apresentados métodos de aprendizado de máquina (Seção 2.5), na qual se deu um maior foco a redes neurais (Seção 2.6, Seção 2.7). Em seguida foram abordados métricas de avaliação de modelos preditivos (Seção 2.8) e no final da seção (Seção 2.9) foram apresentados os trabalhos correlatos.

Em seguida foi proposto um método de recomendações aplicado a o mercado de ações que utilizando técnicas de redes neurais artificiais (Capítulo 3). Para isto foi caracterizada a pesquisa que foi feita para se chegar a este método (Seção 3.1). Foram explicadas as decisões que levaram a construção do método (Seção 3.2). Em (Seção 3.3) foram abordados os dados de treinamento e teste, assim como as manipulações realizadas nos mesmos. Na (Seção 3.4) é explicado as decisões relativas ao treinamento do modelo.

A abordagem proposta foi implementada no Capítulo 4. O capítulo começa apresentado uma análise do conjunto de dados utilizado para treinamento dos modelos e avaliação dos resultados (Seção 4.1). Em Seção 4.2 explorado o método que levou a escolha dos *hyper* parâmetros. Na Seção 4.3 são apresentados e discutidos os resultados experimentais. E por fim, na Seção 4.4, são comparados os trabalhos encontrados na literatura com este, dentro de suas limitações.

Para finalizar este trabalho são discutidas as dificuldades e limitações encontradas ao longo de seu desenvolvimento, como isso afetou o resultado final do trabalho e o conteúdo nele abordado. São então discutidos os pontos que diferem este trabalho de outros e quais são suas possíveis contribuições. Em seguida é retomada a discussão dos resultados obtidos, onde algumas observações pontuais são realizadas e alguns pontos citados anteriormente são enfatizados. Por fim são apresentados algumas possibilidades de continuação e evolução deste trabalho.

5.1 Dificuldades e limitações

Ao longo do desenvolvimento deste trabalho foram encontradas diversas dificuldades, relacionadas a acesso a informações, material e complexidade do tema abordado.

Contudo, são elencadas aqui dificuldades que impossibilitam que algum experimento fosse executado, assim como problemas relacionados a omissão de informações e discordância entre trabalhos.

Uma das dificuldades encontradas foi a divergência entre resultados de qual melhor arquitetura para prever o mercado de ações. Enquanto Selvin et al. (2017) apontam, em seus estudos, que uma arquitetura do tipo CNN obtém maior taxa de acertos, quando comparado com outras arquiteturas, Khirbat, Gupta e Singh (2013) indicam que uma variação da arquitetura *feedforward* obtém maior taxa de acerto, dentro do conjunto de dados testados por ele. Esta dissensão se estende a outros trabalhos (ROONDIWALA; PATEL; VARMA, 2017; MOGHADDAM; MOGHADDAM; ESFANDYARI, 2016; HASSAN; NATH; KIRLEY, 2007; MÄKINEN et al., 2019), fazendo com que a escolha de uma arquitetura, através da comparação de trabalhos publicados na literatura, uma tarefa complexa.

Outra dificuldade foi a reprodução dos resultados apresentados nos trabalhos correlatos, e por consequência a comparação entre trabalhos. Houve dificuldade na obtenção dos dados utilizados nos experimentos descritos pelos trabalhos correlatos (ROONDIWALA; PATEL; VARMA, 2017; SELVIN et al., 2017; MOGHADDAM; MOGHADDAM; ESFANDYARI, 2016; HASSAN; NATH; KIRLEY, 2007), assim como na obtenção do código fonte utilizado para gerar os resultados. Estes trabalhos também acabam omitindo alguns dos parâmetros necessários para reprodução do experimento. Isto dificultou não só a comparação entre trabalhos, como não permitiu que as arquiteturas levantadas neste trabalho fossem testadas no mesmo conjunto de dados que os trabalhos correlatos e seus resultados comparados de forma mais igualitária.

Outro fator que afetou os resultados obtidos neste trabalho foram as limitações encontradas ao longo da sua excussão. O tempo de treinamento de diferentes RNA, assim como a busca por *grid* de seus *hyper* parâmetros, é influenciado pelos recursos computacionais disponíveis para realizar o experimento. Logo, é possível hipotetizar que caso mais recursos computacionais estivessem disponíveis poderia ser ampliado a quantidade e parâmetros buscados por *grid*, assim como o número de experimentos realizados. Houve também limitação de tempo, isso acabou impossibilitando a investigação de uma possível correlação entre a variabilidade de uma ação e a capacidade de prever seu comportamento.

5.2 Trabalhos futuros

Algumas possibilidades de estudo, abordagens e testes não foram executados neste trabalho, dando possibilidade para continuação e evolução do mesmo.

- Otimização de *hyper* parâmetros para cada ação.
- Avaliar o impacto de medidas de dispersão de uma ação na capacidade de uma RNA aprenda e preveja seu comportamento.
- Ampliar a quantidade de parâmetros na busca por *Grid*.

REFERÊNCIAS

- ATSALAKIS, G. S.; VALAVANIS, K. P. Surveying stock market forecasting techniques—part ii: Soft computing methods. **Expert Systems with Applications**, Elsevier, v. 36, n. 3, p. 5932–5941, 2009.
- AZOFF, E. M. **Neural network time series forecasting of financial markets**. [S.l.]: John Wiley & Sons, Inc., 1994.
- BAK, P.; PACZUSKI, M.; SHUBIK, M. Price variations in a stock market with many agents. **arXiv preprint cond-mat/9609144**, 1996.
- BERGSTRA, J. S. et al. Algorithms for hyper-parameter optimization. In: **Advances in neural information processing systems**. [S.l.: s.n.], 2011. p. 2546–2554.
- BOX, G. E. et al. **Time series analysis: forecasting and control**. [S.l.]: John Wiley & Sons, 2015.
- CHEN, N.-F.; ROLL, R.; ROSS, S. A. Economic forces and the stock market. **Journal of business**, JSTOR, p. 383–403, 1986.
- COLBY, R. W.; MEYERS, T. A. **The encyclopedia of technical market indicators**. [S.l.]: Dow Jones-Irwin Homewood, IL, 1988.
- CONNORS, L.; CONNORS, L. A. **Connors on Advanced Trading Strategies**. [S.l.]: M. Gordon Publishing Group, 1998.
- DASE, R.; PAWAR, D. Application of artificial neural network for stock market predictions: A review of literature. **International Journal of Machine Intelligence**, Bioinfo Publications, 49, Vighnagar Shopping Complex Kharghar, Navi Mumbai ..., v. 2, n. 2, p. 14–17, 2010.
- DEAKIN, R.; KILDEA, D. A note on standard deviation and rms. **Australian surveyor**, Taylor & Francis, v. 44, n. 1, p. 74–79, 1999.
- EDWARDS, R. D.; MAGEE, J.; BASSETTI, W. C. **Technical analysis of stock trends**. [S.l.]: CRC press, 2018.
- FARLEY, A. 20 rules for the master swing trader. McGraw-Hill, 2000.
- FEURER, M.; SPRINGENBERG, J. T.; HUTTER, F. Initializing bayesian hyperparameter optimization via meta-learning. In: **Twenty-Ninth AAAI Conference on Artificial Intelligence**. [S.l.: s.n.], 2015.
- FREDERIC, S. M. The economics of money, banking and financial markets. **Mishkin Frederic–Addison Wesley Longman**, 2004.
- FRITZKE, B. Growing cell structures—a self-organizing network for unsupervised and supervised learning. **Neural networks**, Elsevier, v. 7, n. 9, p. 1441–1460, 1994.
- GERS, F. A.; SCHRAUDOLPH, N. N.; SCHMIDHUBER, J. Learning precise timing with lstm recurrent networks. **Journal of machine learning research**, v. 3, n. Aug, p. 115–143, 2002.

GOMES, F. R. A bolsa de valores brasileira como fonte de informações financeiras. **Perspectivas em ciência da informação**, v. 2, n. 2, 1997.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep learning**. [S.l.]: MIT press, 2016.

GREFF, K. et al. Lstm: A search space odyssey. **IEEE transactions on neural networks and learning systems**, IEEE, v. 28, n. 10, p. 2222–2232, 2016.

GRIMA, S.; CARUANA, L. The effect of the financial crisis on emerging markets. a comparative analysis of the stock market situation before and after. In: SVEUČILIŠTE U DUBROVNIKU. **DIEM: Dubrovnik International Economic Meeting**. [S.l.], 2017. v. 3, n. 1, p. 228–254.

HASSAN, M. R.; NATH, B.; KIRLEY, M. A fusion model of hmm, ann and ga for stock market forecasting. **Expert systems with Applications**, Elsevier, v. 33, n. 1, p. 171–180, 2007.

HIRANSHA, M. et al. Nse stock market prediction using deep-learning models. **Procedia computer science**, Elsevier, v. 132, p. 1351–1362, 2018.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural computation**, MIT Press, v. 9, n. 8, p. 1735–1780, 1997.

HSU, M.-W. et al. Bridging the divide in financial market forecasting: machine learners vs. financial economists. **Expert Systems with Applications**, Elsevier, v. 61, p. 215–234, 2016.

JOACHIMS, T. **Making large-scale SVM learning practical**. [S.l.], 1998.

KHIRBAT, G.; GUPTA, R.; SINGH, S. Optimal neural network architecture for stock market forecasting. In: IEEE. **2013 International Conference on Communication Systems and Network Technologies**. [S.l.], 2013. p. 557–561.

KUO, C.-C. J. Understanding convolutional neural networks with a mathematical model. **Journal of Visual Communication and Image Representation**, Elsevier, v. 41, p. 406–413, 2016.

LEBARON, B.; ARTHUR, W. B.; PALMER, R. Time series properties of an artificial stock market. **Journal of Economic Dynamics and control**, Elsevier, v. 23, n. 9-10, p. 1487–1516, 1999.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **nature**, Nature Publishing Group, v. 521, n. 7553, p. 436, 2015.

LECUN, Y. A. et al. Efficient backprop. In: **Neural networks: Tricks of the trade**. [S.l.]: Springer, 2012. p. 9–48.

LEWIS, C. D. **Industrial and business forecasting methods: A practical guide to exponential smoothing and curve fitting**. [S.l.]: Butterworth-Heinemann, 1982.

LIEN, K. **Day trading and swing trading the currency market: technical and fundamental strategies to profit from market moves**. [S.l.]: John Wiley & Sons, 2008. v. 431.

LIN, T. et al. Learning long-term dependencies in narx recurrent neural networks. **IEEE Transactions on Neural Networks**, IEEE, v. 7, n. 6, p. 1329–1338, 1996.

MÄKINEN, Y. et al. Forecasting jump arrivals in stock prices: new attention-based network architecture using limit order book data. **Quantitative Finance**, Taylor & Francis, v. 19, n. 12, p. 2033–2050, 2019.

MALKIEL, B. G. **A random walk down Wall Street: including a life-cycle guide to personal investing**. [S.l.]: WW Norton & Company, 1999.

MENON, V. K. et al. Bulk price forecasting using spark over nse data set. In: SPRINGER. **International Conference on Data Mining and Big Data**. [S.l.], 2016. p. 137–146.

MISHKIN, F. S. **The economics of money, banking, and financial markets**. [S.l.]: Pearson education, 2007.

MJOLSNESS, E.; SHARP, D. H.; ALPERT, B. K. Scaling, machine learning, and genetic neural nets. **Advances in applied mathematics**, Elsevier, v. 10, n. 2, p. 137–163, 1989.

MOGHADDAM, A. H.; MOGHADDAM, M. H.; ESFANDYARI, M. Stock market index prediction using artificial neural network. **Journal of Economics, Finance and Administrative Science**, Elsevier, v. 21, n. 41, p. 89–93, 2016.

NIELSEN, M. A. **Neural networks and deep learning**. [S.l.]: Determination press San Francisco, CA, USA:, 2015. v. 25.

OJA, E. Unsupervised learning in neural computation. **Theoretical computer science**, Elsevier, v. 287, n. 1, p. 187–207, 2002.

PAN, H. A swingtum theory of intelligent finance for swing trading and momentum trading. **2004). A revised version submitted to a finance journal**, Citeseer, 2004.

PRODANOV, C. C.; FREITAS, E. C. de. **Metodologia do trabalho científico: métodos e técnicas da pesquisa e do trabalho acadêmico-2ª Edição**. [S.l.]: Editora Feevale, 2013.

RASCHKE, L. B.; CONNORS, L. A. Street smarts: High probability short-term trading strategies. M. Gordon Publishing Group, 1996.

REIMERS, N.; GUREVYCH, I. Optimal hyperparameters for deep lstm-networks for sequence labeling tasks. **arXiv preprint arXiv:1707.06799**, 2017.

ROJAS, R. **Neural networks: a systematic introduction**. [S.l.]: Springer Science & Business Media, 2013.

ROONDIWALA, M.; PATEL, H.; VARMA, S. Predicting stock prices using lstm. **International Journal of Science and Research (IJSR)**, v. 6, n. 4, p. 1754–1756, 2017.

SAFAVIAN, S. R.; LANDGREBE, D. A survey of decision tree classifier methodology. **IEEE transactions on systems, man, and cybernetics**, IEEE, v. 21, n. 3, p. 660–674, 1991.

SAFFI, P. A.; SIGURDSSON, K. Price efficiency and short selling. **The Review of Financial Studies**, Oxford University Press, v. 24, n. 3, p. 821–852, 2011.

SELVIN, S. et al. Stock price prediction using lstm, rnn and cnn-sliding window model. In: IEEE. **2017 international conference on advances in computing, communications and informatics (icacci)**. [S.l.], 2017. p. 1643–1647.

SEZER, O. B.; OZBAYOGLU, M.; DOGDU, E. A deep neural-network based stock trading system based on evolutionary optimized technical analysis parameters. **Procedia computer science**, Elsevier, v. 114, p. 473–480, 2017.

SHALEV-SHWARTZ, S.; BEN-DAVID, S. **Understanding machine learning: From theory to algorithms**. [S.l.]: Cambridge university press, 2014.

SRIVASTAVA, N. Improving neural networks with dropout. **University of Toronto**, v. 182, n. 566, p. 7, 2013.

VAFAEIPOUR, M. et al. Application of sliding window technique for prediction of wind velocity time series. **International Journal of Energy and Environmental Engineering**, Springer, v. 5, n. 2-3, p. 105, 2014.

VUI, C. S. et al. A review of stock market prediction with artificial neural network (ann). In: IEEE. **2013 IEEE international conference on control system, computing and engineering**. [S.l.], 2013. p. 477–482.

WEIGEND, A. S. **Time series prediction: forecasting the future and understanding the past**. [S.l.]: Routledge, 2018.

WITTEN, I. H. et al. **Data Mining: Practical machine learning tools and techniques**. [S.l.]: Morgan Kaufmann, 2016.

WU, J. Introduction to convolutional neural networks. **National Key Lab for Novel Software Technology. Nanjing University. China**, p. 5–23, 2017.

ZANERO, S.; SAVARESI, S. M. Unsupervised learning techniques for an intrusion detection system. In: ACM. **Proceedings of the 2004 ACM symposium on Applied computing**. [S.l.], 2004. p. 412–419.

ZHANG, G. P. Time series forecasting using a hybrid arima and neural network model. **Neurocomputing**, Elsevier, v. 50, p. 159–175, 2003.

APÊNDICE A – GRID SEARCH

Network Configuration	Dropout	Activation Function	RMSE	R2
[8, 16, 16, 32]	[0, 0, 0, 0.2]	relu	0.061136	0.915284
[8, 16, 16, 32]	[0, 0, 0, 0.2]	tanh	0.050816	0.941471
[8, 16, 16, 32]	[0, 0, 0.2, 0.2]	relu	0.051974	0.938773
[8, 16, 16, 32]	[0, 0, 0.2, 0.2]	tanh	0.053476	0.935184
[8, 16, 16, 32]	[0, 0, 0, 0]	relu	0.562737	-6.177606
[8, 16, 16, 32]	[0, 0, 0, 0]	tanh	0.0598	0.918948
[8, 16, 16, 32]	[0, 0, 0.2, 0.2]	relu	0.054618	0.932385
[8, 16, 16, 32]	[0, 0, 0.2, 0.2]	tanh	0.049177	0.945186
[8, 16, 16, 32]	[0, 0, 0, 0.2]	relu	0.053762	0.934489
[8, 16, 16, 32]	[0, 0, 0, 0.2]	tanh	0.054672	0.932252
[8, 16, 16, 32]	[0, 0, 0.2, 0.5]	relu	0.062525	0.911392
[8, 16, 16, 32]	[0, 0, 0.2, 0.5]	tanh	0.061718	0.913665
[8, 16, 16, 32]	[0, 0, 0, 0.5]	relu	0.562094	-6.161212
[8, 16, 16, 32]	[0, 0, 0, 0.5]	tanh	0.052484	0.937567
[8, 16, 32, 64]	[0, 0, 0, 0.2]	relu	0.562737	-6.177606
[8, 16, 32, 64]	[0, 0, 0, 0.2]	tanh	0.072698	0.880211
[8, 16, 32, 64]	[0, 0, 0.2, 0.2]	relu	0.562737	-6.177606
[8, 16, 32, 64]	[0, 0, 0.2, 0.2]	tanh	0.056288	0.928187
[8, 16, 32, 64]	[0, 0, 0, 0]	relu	0.062326	0.911956
[8, 16, 32, 64]	[0, 0, 0, 0]	tanh	0.047996	0.947788
[8, 16, 32, 64]	[0, 0, 0.2, 0.2]	relu	0.562737	-6.177606
[8, 16, 32, 64]	[0, 0, 0.2, 0.2]	tanh	0.074815	0.873135
[8, 16, 32, 64]	[0, 0, 0, 0.2]	relu	0.064861	0.904646
[8, 16, 32, 64]	[0, 0, 0, 0.2]	tanh	0.079832	0.855548
[8, 16, 32, 64]	[0, 0, 0.2, 0.5]	relu	0.067828	0.895724
[8, 16, 32, 64]	[0, 0, 0.2, 0.5]	tanh	0.04453	0.955055
[8, 16, 32, 64]	[0, 0, 0, 0.5]	relu	0.055748	0.929558
[8, 16, 32, 64]	[0, 0, 0, 0.5]	tanh	0.052793	0.936829
[8, 16, 32, 32]	[0, 0, 0, 0.2]	relu	0.562737	-6.177606
[8, 16, 32, 32]	[0, 0, 0, 0.2]	tanh	0.047953	0.947881

[8, 16, 32, 32]	[0, 0, 0.2, 0.2]	relu	0.052811	0.936787
[8, 16, 32, 32]	[0, 0, 0.2, 0.2]	tanh	0.063295	0.909194
[8, 16, 32, 32]	[0, 0, 0, 0]	relu	0.069396	0.890846
[8, 16, 32, 32]	[0, 0, 0, 0]	tanh	0.052795	0.936824
[8, 16, 32, 32]	[0, 0, 0.2, 0.2]	relu	0.05746	0.925167
[8, 16, 32, 32]	[0, 0, 0.2, 0.2]	tanh	0.056198	0.928416
[8, 16, 32, 32]	[0, 0, 0, 0.2]	relu	0.562737	-6.177606
[8, 16, 32, 32]	[0, 0, 0, 0.2]	tanh	0.061194	0.915123
[8, 16, 32, 32]	[0, 0, 0.2, 0.5]	relu	0.052363	0.937853
[8, 16, 32, 32]	[0, 0, 0.2, 0.5]	tanh	0.052375	0.937825
[8, 16, 32, 32]	[0, 0, 0, 0.5]	relu	0.062262	0.912136
[8, 16, 32, 32]	[0, 0, 0, 0.5]	tanh	0.047282	0.949328
[16, 32, 64, 128]	[0, 0, 0, 0.2]	relu	0.060923	0.915873
[16, 32, 64, 128]	[0, 0, 0, 0.2]	tanh	0.054298	0.933176
[16, 32, 64, 128]	[0, 0, 0.2, 0.2]	relu	0.059457	0.919873
[16, 32, 64, 128]	[0, 0, 0.2, 0.2]	tanh	0.055253	0.930805
[16, 32, 64, 128]	[0, 0, 0, 0]	relu	0.048193	0.947358
[16, 32, 64, 128]	[0, 0, 0, 0]	tanh	0.049271	0.944977
[16, 32, 64, 128]	[0, 0, 0.2, 0.2]	relu	0.060011	0.918375
[16, 32, 64, 128]	[0, 0, 0.2, 0.2]	tanh	0.050537	0.942112
[16, 32, 64, 128]	[0, 0, 0, 0.2]	relu	0.049062	0.945441
[16, 32, 64, 128]	[0, 0, 0, 0.2]	tanh	0.060037	0.918304
[16, 32, 64, 128]	[0, 0, 0.2, 0.5]	relu	0.562737	-6.177606
[16, 32, 64, 128]	[0, 0, 0.2, 0.5]	tanh	0.056369	0.92798
[16, 32, 64, 128]	[0, 0, 0, 0.5]	relu	0.058256	0.923079
[16, 32, 64, 128]	[0, 0, 0, 0.5]	tanh	0.055735	0.929593
[32, 64, 64, 128]	[0, 0, 0, 0.2]	relu	0.057368	0.925405
[32, 64, 64, 128]	[0, 0, 0, 0.2]	tanh	0.058671	0.921977
[32, 64, 64, 128]	[0, 0, 0.2, 0.2]	relu	0.050449	0.942313
[32, 64, 64, 128]	[0, 0, 0.2, 0.2]	tanh	0.050394	0.942439
[32, 64, 64, 128]	[0, 0, 0, 0]	relu	0.060158	0.917974
[32, 64, 64, 128]	[0, 0, 0, 0]	tanh	0.055219	0.93089
[32, 64, 64, 128]	[0, 0, 0.2, 0.2]	relu	0.046776	0.950408

[32, 64, 64, 128]	[0, 0, 0.2, 0.2]	tanh	0.053988	0.933936
[32, 64, 64, 128]	[0, 0, 0, 0.2]	relu	0.063241	0.909351
[32, 64, 64, 128]	[0, 0, 0, 0.2]	tanh	0.062608	0.911156
[32, 64, 64, 128]	[0, 0, 0.2, 0.5]	relu	0.050516	0.94216
[32, 64, 64, 128]	[0, 0, 0.2, 0.5]	tanh	0.050261	0.942742
[32, 64, 64, 128]	[0, 0, 0, 0.5]	relu	0.055422	0.930382
[32, 64, 64, 128]	[0, 0, 0, 0.5]	tanh	0.052611	0.937263
[32, 32, 32, 32]	[0, 0, 0, 0.2]	relu	0.058511	0.922404
[32, 32, 32, 32]	[0, 0, 0, 0.2]	tanh	0.054433	0.932842
[32, 32, 32, 32]	[0, 0, 0.2, 0.2]	relu	0.051511	0.939859
[32, 32, 32, 32]	[0, 0, 0.2, 0.2]	tanh	0.053075	0.936152
[32, 32, 32, 32]	[0, 0, 0, 0]	relu	0.051184	0.94062
[32, 32, 32, 32]	[0, 0, 0, 0]	tanh	0.059066	0.920925
[32, 32, 32, 32]	[0, 0, 0.2, 0.2]	relu	0.055081	0.931234
[32, 32, 32, 32]	[0, 0, 0.2, 0.2]	tanh	0.05364	0.934785
[32, 32, 32, 32]	[0, 0, 0, 0.2]	relu	0.058888	0.921401
[32, 32, 32, 32]	[0, 0, 0, 0.2]	tanh	0.061563	0.914096
[32, 32, 32, 32]	[0, 0, 0.2, 0.5]	relu	0.047613	0.948618
[32, 32, 32, 32]	[0, 0, 0.2, 0.5]	tanh	0.061017	0.915614
[32, 32, 32, 32]	[0, 0, 0, 0.5]	relu	0.05553	0.930109
[32, 32, 32, 32]	[0, 0, 0, 0.5]	tanh	0.050539	0.942107
[8, 16, 32, 32, 64]	[0, 0, 0, 0, 0]	relu	0.055715	0.929643
[8, 16, 32, 32, 64]	[0, 0, 0, 0, 0]	tanh	0.077975	0.862192
[8, 16, 32, 32, 64]	[0, 0, 0.2, 0.2, 0.2]	relu	0.562737	-6.177606
[8, 16, 32, 32, 64]	[0, 0, 0.2, 0.2, 0.2]	tanh	0.054748	0.932064
[8, 16, 32, 32, 64]	[0, 0, 0, 0.2, 0.2]	relu	0.046266	0.951483
[8, 16, 32, 32, 64]	[0, 0, 0, 0.2, 0.2]	tanh	0.064013	0.907125
[8, 16, 32, 32, 64]	[0, 0, 0, 0, 0.5]	relu	0.562737	-6.177606
[8, 16, 32, 32, 64]	[0, 0, 0, 0, 0.5]	tanh	0.059727	0.919144
[8, 16, 32, 32, 64]	[0, 0, 0.2, 0.3, 0.5]	relu	0.052055	0.938583
[8, 16, 32, 32, 64]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.051686	0.939451
[8, 16, 32, 32, 64]	[0, 0, 0, 0.3, 0.5]	relu	0.058693	0.921919
[8, 16, 32, 32, 64]	[0, 0, 0, 0.3, 0.5]	tanh	0.058399	0.9227

[8, 8, 16, 32, 32]	[0, 0, 0, 0, 0]	relu	0.562737	-6.177606
[8, 8, 16, 32, 32]	[0, 0, 0, 0, 0]	tanh	0.06358	0.908376
[8, 8, 16, 32, 32]	[0, 0, 0.2, 0.2, 0.2]	relu	0.06375	0.907885
[8, 8, 16, 32, 32]	[0, 0, 0.2, 0.2, 0.2]	tanh	0.050772	0.941572
[8, 8, 16, 32, 32]	[0, 0, 0, 0.2, 0.2]	relu	0.058481	0.922482
[8, 8, 16, 32, 32]	[0, 0, 0, 0.2, 0.2]	tanh	0.049033	0.945507
[8, 8, 16, 32, 32]	[0, 0, 0, 0, 0.5]	relu	0.048879	0.945847
[8, 8, 16, 32, 32]	[0, 0, 0, 0, 0.5]	tanh	0.046472	0.951051
[8, 8, 16, 32, 32]	[0, 0, 0.2, 0.3, 0.5]	relu	0.562737	-6.177606
[8, 8, 16, 32, 32]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.04923	0.945068
[8, 8, 16, 32, 32]	[0, 0, 0, 0.3, 0.5]	relu	0.053828	0.934326
[8, 8, 16, 32, 32]	[0, 0, 0, 0.3, 0.5]	tanh	0.050879	0.941326
[16, 16, 32, 32, 64]	[0, 0, 0, 0, 0]	relu	0.059693	0.919238
[16, 16, 32, 32, 64]	[0, 0, 0, 0, 0]	tanh	0.0544	0.932925
[16, 16, 32, 32, 64]	[0, 0, 0.2, 0.2, 0.2]	relu	0.562737	-6.177606
[16, 16, 32, 32, 64]	[0, 0, 0.2, 0.2, 0.2]	tanh	0.048952	0.945685
[16, 16, 32, 32, 64]	[0, 0, 0, 0.2, 0.2]	relu	0.562737	-6.177606
[16, 16, 32, 32, 64]	[0, 0, 0, 0.2, 0.2]	tanh	0.052054	0.938586
[16, 16, 32, 32, 64]	[0, 0, 0, 0, 0.5]	relu	0.06847	0.893741
[16, 16, 32, 32, 64]	[0, 0, 0, 0, 0.5]	tanh	0.055198	0.930943
[16, 16, 32, 32, 64]	[0, 0, 0.2, 0.3, 0.5]	relu	0.051583	0.93969
[16, 16, 32, 32, 64]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.058014	0.923715
[16, 16, 32, 32, 64]	[0, 0, 0, 0.3, 0.5]	relu	0.05967	0.919299
[16, 16, 32, 32, 64]	[0, 0, 0, 0.3, 0.5]	tanh	0.04727	0.949356
[16, 32, 32, 64, 128]	[0, 0, 0, 0, 0]	relu	0.060161	0.917964
[16, 32, 32, 64, 128]	[0, 0, 0, 0, 0]	tanh	0.049072	0.945419
[16, 32, 32, 64, 128]	[0, 0, 0.2, 0.2, 0.2]	relu	0.562737	-6.177606
[16, 32, 32, 64, 128]	[0, 0, 0.2, 0.2, 0.2]	tanh	0.054152	0.933535
[16, 32, 32, 64, 128]	[0, 0, 0, 0.2, 0.2]	relu	0.04836	0.946993
[16, 32, 32, 64, 128]	[0, 0, 0, 0.2, 0.2]	tanh	0.054913	0.931654
[16, 32, 32, 64, 128]	[0, 0, 0, 0, 0.5]	relu	0.055923	0.929116
[16, 32, 32, 64, 128]	[0, 0, 0, 0, 0.5]	tanh	0.049452	0.944571
[16, 32, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	relu	0.562737	-6.177606

[16, 32, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.045502	0.953072
[16, 32, 32, 64, 128]	[0, 0, 0, 0.3, 0.5]	relu	0.562737	-6.177606
[16, 32, 32, 64, 128]	[0, 0, 0, 0.3, 0.5]	tanh	0.048554	0.946566
[16, 16, 32, 64, 128]	[0, 0, 0, 0, 0]	relu	0.562706	-6.176796
[16, 16, 32, 64, 128]	[0, 0, 0, 0, 0]	tanh	0.057625	0.924735
[16, 16, 32, 64, 128]	[0, 0, 0.2, 0.2, 0.2]	relu	0.055997	0.928929
[16, 16, 32, 64, 128]	[0, 0, 0.2, 0.2, 0.2]	tanh	0.049035	0.945502
[16, 16, 32, 64, 128]	[0, 0, 0, 0.2, 0.2]	relu	0.562737	-6.177606
[16, 16, 32, 64, 128]	[0, 0, 0, 0.2, 0.2]	tanh	0.049574	0.944297
[16, 16, 32, 64, 128]	[0, 0, 0, 0, 0.5]	relu	0.562737	-6.177606
[16, 16, 32, 64, 128]	[0, 0, 0, 0, 0.5]	tanh	0.054443	0.932818
[16, 16, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	relu	0.562737	-6.177606
[16, 16, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.053744	0.934532
[16, 16, 32, 64, 128]	[0, 0, 0, 0.3, 0.5]	relu	0.562737	-6.177606
[16, 16, 32, 64, 128]	[0, 0, 0, 0.3, 0.5]	tanh	0.049477	0.944515
[8, 16, 32, 64, 128]	[0, 0, 0, 0, 0]	relu	0.060081	0.918184
[8, 16, 32, 64, 128]	[0, 0, 0, 0, 0]	tanh	0.074588	0.873903
[8, 16, 32, 64, 128]	[0, 0, 0.2, 0.2, 0.2]	relu	0.046222	0.951575
[8, 16, 32, 64, 128]	[0, 0, 0.2, 0.2, 0.2]	tanh	0.055517	0.93014
[8, 16, 32, 64, 128]	[0, 0, 0, 0.2, 0.2]	relu	0.045852	0.952347
[8, 16, 32, 64, 128]	[0, 0, 0, 0.2, 0.2]	tanh	0.052297	0.93801
[8, 16, 32, 64, 128]	[0, 0, 0, 0, 0.5]	relu	0.055944	0.929062
[8, 16, 32, 64, 128]	[0, 0, 0, 0, 0.5]	tanh	0.050794	0.941522
[8, 16, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	relu	0.562737	-6.177606
[8, 16, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.049213	0.945106
[8, 16, 32, 64, 128]	[0, 0, 0, 0.3, 0.5]	relu	0.562737	-6.177606
[8, 16, 32, 64, 128]	[0, 0, 0, 0.3, 0.5]	tanh	0.061476	0.914339

Fonte: Próprio autor (2020)

APÊNDICE A – TODAS AS AÇÕES

Tabela 13 – Avaliação das ações

Nome	Feature	Network	Dropout	Função de ativação	REQM	EQM	R2	EMPA
PETR	Fechamento	[8, 16, 32, 64]	[0, 0, 0.2, 0.5]	tanh	0.051781	0.002681	0.939228	0.077717
PETR	Abertura	[8, 16, 32, 64]	[0, 0, 0.2, 0.5]	tanh	0.057561	0.003313	0.911918	0.092292
PETR	Fechamento	[16, 32, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.053415	0.002853	0.935332	0.088508
PETR	Abertura	[16, 32, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.065119	0.004241	0.887268	0.103604
VALE	Fechamento	[8, 16, 32, 64]	[0, 0, 0.2, 0.5]	tanh	0.050496	0.00255	0.936329	0.070754
VALE	Abertura	[8, 16, 32, 64]	[0, 0, 0.2, 0.5]	tanh	0.057185	0.00327	0.908653	0.076459
VALE	Fechamento	[16, 32, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.050673	0.002568	0.935881	0.067569
VALE	Abertura	[16, 32, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.049643	0.002464	0.931161	0.065955
ITUB	Fechamento	[8, 16, 32, 64]	[0, 0, 0.2, 0.5]	tanh	0.043699	0.00191	0.950668	0.06543
ITUB	Abertura	[8, 16, 32, 64]	[0, 0, 0.2, 0.5]	tanh	0.052889	0.002797	0.943377	0.070486
ITUB	Fechamento	[16, 32, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.039386	0.001551	0.959925	0.058971
ITUB	Abertura	[16, 32, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.055004	0.003025	0.938759	0.072123
BBDC	Fechamento	[8, 16, 32, 64]	[0, 0, 0.2, 0.5]	tanh	0.031742	0.001008	0.986606	0.053765
BBDC	Abertura	[8, 16, 32, 64]	[0, 0, 0.2, 0.5]	tanh	0.027654	0.000765	0.990116	0.048355
BBDC	Fechamento	[16, 32, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.031138	0.00097	0.987111	0.053008
BBDC	Abertura	[16, 32, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.027462	0.000754	0.990253	0.050674
ABEV	Fechamento	[8, 16, 32, 64]	[0, 0, 0.2, 0.5]	tanh	0.04229	0.001788	0.955663	0.086682
ABEV	Abertura	[8, 16, 32, 64]	[0, 0, 0.2, 0.5]	tanh	0.0434	0.001884	0.94057	0.072592
ABEV	Fechamento	[16, 32, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.040249	0.00162	0.959839	0.082764
ABEV	Abertura	[16, 32, 32, 64, 128]	[0, 0, 0.2, 0.3, 0.5]	tanh	0.046375	0.002151	0.932145	0.077632

Fonte: Próprio autor (2020)

ANEXO A – COTAÇÕES HISTÓRICAS

Capítulo

Revisão

Data

I. Layout do Arquivo de Cotações Históricas – COTAHIST.AAAA.TXT

00

22/09/05

1 CONCEITOS BÁSICOS

O arquivo COTAHIST.AAAA.TXT contém as informações das cotações históricas relativas à negociação de todos os papéis-mercado no período de um ano, classificado pelos campos Tipo de registro, Data do pregão, Código de BDI, Nome da empresa e Código de Negociação. Esta divisão não impede que o usuário o classifique de acordo com as suas necessidades, segundo o equipamento e software a serem usados.

O nome do arquivo identifica o ano correspondente.
Ex.: COTAHIST.1990.TXT, COTAHIST.1991.TXT, Etc.

2 ESTRUTURA DO ARQUIVO

Nome do Arquivo: **COTAHIST.AAAA.TXT**

Tipos de Registros : Cada arquivo é composto por três tipos de registros.

- Registro - 00 - Header
- Registro - 01 - Cotações dos papéis por dia
- Registro - 99 - Trailer

Tamanho dos Registros: 245 bytes.

3 LAYOUT DO ARQUIVO

3.1 REGISTRO - 00 - HEADER

NOME DO CAMPO / DESCRIÇÃO	CONTEÚDO	TIPO E TAMANHO	POSIC. INIC.	POSIC. FINAL
TIPO DE REGISTRO	FIXO "00"	N(02)	01	02
NOME DO ARQUIVO	FIXO "COTAHIST.AAAA"	X(13)	03	15
CÓDIGO DA ORIGEM	FIXO "BOVESPA"	X(08)	16	23
DATA DA GERAÇÃO DO ARQUIVO	FORMATO "AAAAMMDD"	N(08)	24	31
RESERVA	PREENCHER COM BRANCOS	X(214)	32	245

Capítulo

Revisão

Data

I. Layout do Arquivo de Cotações Históricas – COTAHIST.AAAA.TXT

00

22/09/05

3.2 REGISTRO - 01 - COTAÇÕES HISTÓRICAS POR PAPEL-MERCADO

NOME DO CAMPO / DESCRIÇÃO	CONTEÚDO	TIPO E TAMANHO	POSIC. INIC.	POSIC. FINAL
TIPREG - TIPO DE REGISTRO	FIXO "01"	N(02)	01	02
DATA DO PREGÃO	FORMATO "AAAAAMDD"	N(08)	03	10
CODBDI - CÓDIGO BDI	UTILIZADO PARA CLASSIFICAR OS PAPÉIS NA EMISSÃO DO BOLETIM DIÁRIO DE INFORMAÇÕES VER TABELA ANEXA	X(02)	11	12
CODNEG - CÓDIGO DE NEGOCIAÇÃO DO PAPEL		X(12)	13	24
TPMERC - TIPO DE MERCADO	CÓD. DO MERCADO EM QUE O PAPEL ESTÁ CADASTRADO VER TABELA ANEXA	N(03)	25	27
NOMRES - NOME RESUMIDO DA EMPRESA EMISSORA DO PAPEL		X(12)	28	39
ESPECI - ESPECIFICAÇÃO DO PAPEL	VER TABELA ANEXA	X(10)	40	49
PRAZOT - PRAZO EM DIAS DO MERCADO A TERMO		X(03)	50	52
MODREF - MOEDA DE REFERÊNCIA	MOEDA USADA NA DATA DO PREGÃO	X(04)	53	56
PREABE - PREÇO DE ABERTURA DO PAPEL-MERCADO NO PREGÃO		(11)V99	57	69
PREMAX - PREÇO MÁXIMO DO PAPEL-MERCADO NO PREGÃO		(11)V99	70	82
PREMIN - PREÇO MÍNIMO DO PAPEL-MERCADO NO PREGÃO		(11)V99	83	95
PREMED - PREÇO MÉDIO DO PAPEL-MERCADO NO PREGÃO		(11)V99	96	108
PREULT - PREÇO DO ÚLTIMO NEGÓCIO DO PAPEL-MERCADO NO PREGÃO		(11)V99	109	121
PREOFC - PREÇO DA MELHOR OFERTA DE COMPRA DO PAPEL-MERCADO		(11)V99	122	134
PREOFV - PREÇO DA MELHOR OFERTA DE VENDA DO PAPEL-MERCADO		(11)V99	135	147
TOTNEG - NEG. - NÚMERO DE NEGÓCIOS EFETUADOS COM O PAPEL-MERCADO NO PREGÃO		N(05)	148	152
QUATOT - QUANTIDADE TOTAL DE TÍTULOS NEGOCIADOS NESTE PAPEL-MERCADO		N(18)	153	170

Capítulo

Revisão

Data

I. Layout do Arquivo de Cotações Históricas – COTAHIST.AAAA.TXT

00

22/09/05

VOLTOT - VOLUME TOTAL DE TÍTULOS NEGOCIADOS NESTE PAPEL-MERCADO		(16)V99	171	188
PREEXE - PREÇO DE EXERCÍCIO PARA O MERCADO DE OPÇÕES OU VALOR DO CONTRATO PARA O MERCADO DE TERMO SECUNDÁRIO		(11)V99	189	201
INDOPC - INDICADOR DE CORREÇÃO DE PREÇOS DE EXERCÍCIOS OU VALORES DE CONTRATO PARA OS MERCADOS DE OPÇÕES OU TERMO SECUNDÁRIO	VER TABELA ANEXA	N(01)	202	202
DATVEN - DATA DO VENCIMENTO PARA OS MERCADOS DE OPÇÕES OU TERMO SECUNDÁRIO	FORMATO "AAAAMMDD"	N(08)	203	210
FATCOT - FATOR DE COTAÇÃO DO PAPEL	'1' = COTAÇÃO UNITÁRIA '1000' = COTAÇÃO POR LOTE DE MIL AÇÕES	N(07)	211	217
PTOEXE - PREÇO DE EXERCÍCIO EM PONTOS PARA OPÇÕES REFERENCIADAS EM DÓLAR OU VALOR DE CONTRATO EM PONTOS PARA TERMO SECUNDÁRIO	PARA OS REFERENCIADOS EM DÓLAR, CADA PONTO EQUIVALE AO VALOR, NA MOEDA CORRENTE, DE UM CENTÉSIMO DA TAXA MÉDIA DO DÓLAR COMERCIAL INTERBANCÁRIO DE FECHAMENTO DO DIA ANTERIOR, OU SEJA, 1 PONTO = 1/100 US\$	(07)V06	218	230
CODISI - CÓDIGO DO PAPEL NO SISTEMA ISIN OU CÓDIGO INTERNO DO PAPEL	CÓDIGO DO PAPEL NO SISTEMA ISIN A PARTIR DE 15-05-1995	X(12)	231	242
DISMES - NÚMERO DE DISTRIBUIÇÃO DO PAPEL	NÚMERO DE SEQUÊNCIA DO PAPEL CORRESPONDENTE AO ESTADO DE DIREITO VIGENTE	9(03)	243	245

3.3 REGISTRO - 99 - TRAILER

DESCRIÇÃO DO CAMPO	CONTEÚDO	TIPO E TAMANHO	POSIC. INIC.	POSIC. FINAL
TIPO DE REGISTRO	FIXO "99"	N(02)	01	02
NOME DO ARQUIVO	FIXO "COTAHIST.AAAA"	X(13)	03	15
CÓDIGO DA ORIGEM	FIXO "BOVESPA"	X(08)	16	23
DATA DA GERAÇÃO DO ARQUIVO	FORMATO "AAAAMMDD"	N(08)	24	31
TOTAL DE REGISTROS	INCLUIR TAMBÉM OS REGISTROS HEADER E TRAILER.	N(11)	32	42
RESERVA	PREENCHER COM BRANCOS	X(203)	43	245

Capítulo

Revisão

Data

I. Layout do Arquivo de Cotações Históricas – COTAHIST.AAAA.TXT

00

22/09/05

4. TABELAS ANEXAS**TABELA DE IDENTI - RELAÇÃO DOS VALORES PARA ÍNDICES**

01	IBOV	ÍNDICE BOVESPA
02	IEEX	ÍNDICE SETORIAL DE ENERGIA ELÉTRICA
03	IVBX	ÍNDICE IVBX2
04	IBXX	ÍNDICE IBRX BRASIL
05	ITEL	ÍNDICE ITELECOM
06	IBXL	ÍNDICE IBRX 50
07	MIBV	MINI IBOV
08	IGCX	ÍNDICE IGOVERNANÇA
10	ITAG	ITAG ALONG

TABELA DE CODBDI - RELAÇÃO DOS VALORES PARA CÓDIGOS DE BDI

02	LOTE PADRÃO
06	CONCORDATÁRIAS
10	DIREITOS E RECIBOS
12	FUNDOS IMOBILIÁRIOS
14	CERTIFIC. INVESTIMENTO / DEBÊNTURES / TÍTULOS DIVIDA PÚBLICA
18	OBRIGAÇÕES
22	BÔNUS (PRIVADOS)
26	APÓLICES / BÔNUS / TÍTULOS PÚBLICOS
32	EXERCÍCIO DE OPÇÕES DE COMPRA DE ÍNDICE
33	EXERCÍCIO DE OPÇÕES DE VENDA DE ÍNDICE
38	EXERCÍCIO DE OPÇÕES DE COMPRA
42	EXERCÍCIO DE OPÇÕES DE VENDA
46	LEILÃO DE TÍTULOS NÃO COTADOS
48	LEILÃO DE PRIVATIZAÇÃO
50	LEILÃO
51	LEILÃO FINOR
52	LEILÃO FINAM
53	LEILÃO FISET
54	LEILÃO DE AÇÕES EM MORA
56	VENDAS POR ALVARÁ JUDICIAL
58	OUTROS
60	PERMUTA POR AÇÕES
61	META
62	TERMO
66	DEBÊNTURES COM DATA DE VENCIMENTO ATÉ 3 ANOS
68	DEBÊNTURES COM DATA DE VENCIMENTO MAIOR QUE 3 ANOS
70	FUTURO COM MOVIMENTAÇÃO CONTÍNUA
71	FUTURO COM RETENÇÃO DE GANHO
74	OPÇÕES DE COMPRA DE ÍNDICES
75	OPÇÕES DE VENDA DE ÍNDICES
78	OPÇÕES DE COMPRA
82	OPÇÕES DE VENDA
83	DEBÊNTURES E NOTAS PROMISSÓRIAS
96	FRACIONÁRIO
99	TOTAL GERAL

TABELA DE ESPECI - RELAÇÃO DE VALORES PARA AS POSIÇÕES 5, 6,7

ON	AÇÕES ORDINÁRIAS NOMINATIVAS
PNA	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE A
PNB	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE B
PNC	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE C

Capítulo

Revisão

Data

I. Layout do Arquivo de Cotações Históricas – COTAHIST.AAAA.TXT

00

22/09/05

PND	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE D
PNE	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE
PNF	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE F
PNG	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE G
PNH	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE H
PN	AÇÕES PREFERENCIAIS NOMINATIVAS
PNV	AÇÕES PREFERENCIAIS NOMINATIVAS COM DIREITO A VOTO
OR	AÇÕES ORDINÁRIAS NOMINATIVAS RESGATÁVEIS
PRA	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE A RESGATÁVEIS
PRB	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE B RESGATÁVEIS
PRC	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE C RESGATÁVEIS
PRD	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE D RESGATÁVEIS
PRE	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE E RESGATÁVEIS
PRF	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE F RESGATÁVEIS
PRG	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE G RESGATÁVEIS
PRH	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE H RESGATÁVEIS
PNR	AÇÕES PREFERENCIAIS NOMINATIVAS RESGATÁVEIS
PRV	AÇÕES PREFERENCIAIS NOMINATIVAS COM DIREITO A VOTO RESG
ON P	AÇÕES ORDINÁRIAS NOMINATIVAS COM DIREITOS DIFERENCIADOS
PNA P	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE A C/ DIREITOS DIFER
PNB P	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE B C/ DIREITOS DIFER
PNC P	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE C C/ DIREITOS DIFER
PND P	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE D C/ DIREITOS DIFER
PNE P	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE E C/ DIREITOS DIFER
PNF P	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE F C/ DIREITOS DIFER
PNG P	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE G C/ DIREITOS DIFER
PNH P	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE H C/ DIREITOS DIFER
PN P	AÇÕES PREFERENCIAIS NOMINATIVAS COM DIREITOS DIFERENCIADOS
PNV P	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE V C/ DIREITOS DIFER
ON P	AÇÕES ORDINÁRIAS NOMINATIVAS COM DIREITOS DIFERENCIADOS
BDR	BDR
UNT	CERTIFICADO DE DEPOSITO DE AÇÕES - MISCELÂNEA
CDA	CERTIFICADO DE DEPOSITO DE AÇÕES ORDINÁRIAS
CPA	CERTIFICADOS DE POTENCIAL ADICIONAL DE CONSTRUÇÃO E OPERAÇÃO
RON	CESTA DE AÇÕES ORDINÁRIAS NOMINATIVAS
R	CESTA DE AÇÕES NOMINATIVAS
CI	FUNDO DE INVESTIMENTO
DIR	DIREITOS DE SUBSCRIÇÃO MISCELÂNEA (BÔNUS, DEBÊNTURES, ETC)
DIR ORD	DIREITOS DE SUBSCRIÇÃO EM AÇÕES ORDINÁRIAS
DIR P/A	DIREITOS DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE A
DIR P/B	DIREITOS DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE B
DIR P/C	DIREITOS DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE C
DIR P/D	DIREITOS DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE D
DIR P/E	DIREITOS DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE E
DIR P/F	DIREITOS DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE F
DIR P/G	DIREITOS DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE G
DIR P/H	DIREITOS DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE H
DIR PRE	DIREITOS DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS
PRA REC	RECIBO DE SUBSCRIÇÃO EM AÇÕES RESGATÁVEIS PREF. CLASSE A
PRB REC	RECIBO DE SUBSCRIÇÃO EM AÇÕES RESGATÁVEIS PREF. CLASSE B
PRC REC	RECIBO DE SUBSCRIÇÃO EM AÇÕES RESGATÁVEIS PREF. CLASSE C
M1 REC	RECIBO DE SUBSCRIÇÃO DE MISCELÂNEAS
DIR PRA	DIREITOS DE SUBSCRIÇÃO EM AÇÕES RESGATÁVEIS PREF. CLASSE A
DIR PRB	DIREITOS DE SUBSCRIÇÃO EM AÇÕES RESGATÁVEIS PREF. CLASSE B
DIR PRC	DIREITOS DE SUBSCRIÇÃO EM AÇÕES RESGATÁVEIS PREF. CLASSE C
LFT	LETRA FINANCEIRA DO TESOIRO
BNS ORD	BÔNUS DE SUBSCRIÇÃO EM AÇÕES ORDINÁRIAS
BNS P/A	BÔNUS DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE A
BNS P/B	BÔNUS DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE B
BNS P/C	BÔNUS DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE C
BNS P/D	BÔNUS DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE D
BNS P/E	BÔNUS DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE E
BNS P/F	BÔNUS DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE F
BNS P/G	BÔNUS DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE G
BNS P/H	BÔNUS DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE H

Capítulo

Revisão

Data

I. Layout do Arquivo de Cotações Históricas – COTAHIST.AAAA.TXT

00

22/09/05

BNS PRE	BÔNUS DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS
PCD	POSIÇÃO CONSOLIDADA DA DÍVIDA
UP	PRECATÓRIO
REC	RECIBO DE SUBSCRIÇÃO MISCELÂNEA
ON REC	RECIBO DE SUBSCRIÇÃO EM AÇÕES ORDINÁRIAS
PNA REC	RECIBO DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE A
PNB REC	RECIBO DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE B
PNC REC	RECIBO DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE C
PND REC	RECIBO DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE D
PNE REC	RECIBO DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE E
PNF REC	RECIBO DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE F
PNG REC	RECIBO DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE G
PNH REC	RECIBO DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS CLASSE H
PN REC	RECIBO DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS
PNV REC	RECIBO DE SUBSCRIÇÃO EM AÇÕES PREFERENCIAIS C/ DIREITO VOTO
UNT	UNITS
WRT	WARRANTS DE DEBÊNTURES
OR P	AÇÕES ORDINÁRIAS NOMINATIVAS RESGATÁVEIS C/ DIREITOS DIF
PRA P	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE "A" RESG. C/ DIR.DIF
PRB P	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE "B" RESG. C/ DIR.DIF
PRC P	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE "C" RESG. C/ DIR.DIF
PRD P	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE "D" RESG. C/ DIR.DIF
PRE P	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE "E" RESG. C/ DIR.DIF
PRF P	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE "F" RESG. C/ DIR.DIF
PRG P	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE "G" RESG. C/ DIR.DIF
PRH P	AÇÕES PREFERENCIAIS NOMINATIVAS CLASSE "H" RESG. C/ DIR.DIF
PR P	AÇÕES PREFERENCIAIS NOMINATIVAS RESGATÁVEIS C/ DIREITOS DIF
PRV P	AÇÕES PREFERENCIAIS NOMINATIVAS RESG. C/ DIR.DIF. E DIR.VOTO

TABELA DE INDOPC - RELAÇÃO DOS VALORES PARA CORREÇÃO DE CONTRATOS

1	US\$	CORREÇÃO PELA TAXA DO DÓLAR
2	TJLP	CORREÇÃO PELA TJLP
3	TR	CORREÇÃO PELA TR
4	IPCR	CORREÇÃO PELO IPCR
5	SWA	OPÇÕES DE TROCA - SWOPTIONS
6	ÍNDICES (PONTOS)	OPÇÕES REFERENCIADAS EM PONTOS DE ÍNDICE
7	US\$ (PROTEGIDAS)	CORREÇÃO PELA TAXA DO DÓLAR - OPÇÕES PROTEGIDAS
8	IGPM (PROTEGIDA)	CORREÇÃO PELO IGP-M - OPÇÕES PROTEGIDAS
9	URV	CORREÇÃO PELA URV

TABELA DE TPMERC - RELAÇÃO DOS VALORES PARA TIPO DE MERCADO

010	VISTA
012	EXERCÍCIO DE OPÇÕES DE COMPRA
013	EXERCÍCIO DE OPÇÕES DE VENDA
017	LEILÃO
020	FRACIONÁRIO
030	TERMO
050	FUTURO COM RETENÇÃO DE GANHO
060	FUTURO COM MOVIMENTAÇÃO CONTÍNUA
070	OPÇÕES DE COMPRA
080	OPÇÕES DE VENDA

TABELA PROVISÓRIA DE CONVERSÃO DE CODINT PARA ISIN**ESTRUTURA DO CAMPO CODINT**

CÓDIGO INTERNO DE IDENTIFICAÇÃO DE PAPEL USADO ATÉ 14/05/1995. (12 POSIÇÕES)

SOCEMI	PIC X (04)	CÓDIGO DA SOCIEDADE EMISSORA.
TIPTIT	PIC X (02)	TIPO DO TÍTULO

Capítulo

Revisão

Data

I. Layout do Arquivo de Cotações Históricas – COTAHIST.AAAA.TXT

00

22/09/05

ESPANO PIC X (04) ESPÉCIE DO TÍTULO
DISMES PIC 9 (03) COMP-3 CORRESPONDE AO CAMPO QUE CONTINUA ABAIXO DE
CODISI

NA DEFINIÇÃO DO LAYOUT DO COTAHIST (DISMES)

ESTRUTURA DO CAMPO CODISI

CÓDIGO ISIN DE IDENTIFICAÇÃO DE PAPEL, USADO DESDE 15/05/1995. (12 POSIÇÕES)
ESTE CÓDIGO NÃO PODE TER BRANCOS EM SUA ESTRUTURA.

1.- PAÍS	PIC X (02). FIXO BR
2.- EMPRESA EMISSORA	PIC X (04). CAMPO SOCEMI DO CODINT
3.- TIPO DE ATIVO	PIC X (03).
4.- IDENTIFICADOR DE EMISSÃO DE TÍTULO	PIC X (02).
5.- DÍGITO DE CONTROLE	PIC 9 (01).

SE TIPTIT = AC E SEGUNDA POSIÇÃO DO ESPANO = N , TIPO DE ATIVO = ACN

SE TIPTIT = AC E SEGUNDA POSIÇÃO DO ESPANO = N E TERCEIRA POSIÇÃO DO ESPANO = R, TIPO DE ATIVO = ARN

SE TIPTIT = AC E SOCEMI = YPFL, TIPO DE ATIVO = CDA

SE TIPTIT = CI E SOCEMI = UBBR, TIPO DE ATIVO = CDA

SE TIPTIT = IN, TIPO DE ATIVO = IND

SE TIPTIT = B1 OU S1, TIPO DE ATIVO = A01

SE TIPTIT = R1, TIPO DE ATIVO = R01

SE TIPTIT = BC, TIPO DE ATIVO = CPB

SE TIPTIT = CI E SOCEMI = BCBR, TIPO DE ATIVO = CPC

SE TIPTIT = CI, TIPO DE ATIVO = CTF

SE TIPTIT = TX, TIPO DE ATIVO = IND

SE PRIMEIRA POSIÇÃO DO ESPANO = O, IDENTIFICADOR DE TÍTULO = OR

SE PRIMEIRA POSIÇÃO DO ESPANO = P, IDENTIFICADOR DE TÍTULO = PR

SE TERCEIRA POSIÇÃO DO ESPANO = A A H, IDENTIFICADOR DE TÍTULO = PA A PH